# 01 / Agente personal para México

Roadmap, arquitectura y economía | Versión 1.2 | 11 de noviembre de 2026

**Una VM exclusiva y persistente por usuario, con Hermes, navegador, memoria y archivos propios. Identidad, permisos, agenda y pagos fuera de la VM. PWA primero; Finco y WhatsApp sujetos a validación.**

**Objetivo.** Asistente para personas adultas en México que investigue, compare, organice tareas y complete compras autorizadas; español mexicano, precios en MXN y seguimiento hasta entrega o reembolso.

## Resumen ejecutivo actualizado

- **Desarrollo inicial:** MXN 2,606,047.79 de caja modelada para cuatro meses, incluida contingencia de 20%. No es una cotización; faltan Finco, marketing y extras condicionados. El roadmap completo sigue siendo de 24 semanas.
- **Operación mensual:** MXN 114,112 / 242,358 / 1,220,099 para 25 / 100 / 1,000 usuarios, con personal, proveedores y provisión de riesgo. La VM con backup cuesta USD 31.20 por usuario/mes antes de la provisión fiscal.
- **Modelo abierto por API:** probar GPT-OSS-120B en Groq para tareas de texto y Qwen3.6-35B-A3B en DeepInfra para pantallas. Cerebras queda para evaluar máxima velocidad y cotizar producción. Sin GPU por usuario ni benchmarks ejecutados.
- **Diferenciación:** Muse ya llegó a México el 5 de noviembre según el anuncio recibido. Hay que ganar en servicios locales, ejecución, soporte y economía, no solo en disponibilidad. [S01]
- **Dinero y canales:** cobrar el servicio, fondear una cuenta y pagar al comercio son tres flujos distintos. Link documenta cuentas US/Canadá. WhatsApp restringe asistentes generalistas de terceros; México no figura en las excepciones EEE/Brasil citadas. [S10–S11, S25]

## Cómo leer el documento

Secciones 02–20: producto, arquitectura, seguridad, backlog P00–P33 y roadmap. Secciones 21–38: costos, supuestos, modelos, velocidad y hosting. Secciones 39 en adelante: fuentes y alcance de verificación.

Tarifas externas: antecedente de investigación del 11/11/2026 facilitado en la continuación. Esta sesión verificó aritmética y documentación GitHub; varios portales de precios quedaron bloqueados por la red. No hubo despliegues, compras, mensajes a proveedores ni llamadas pagadas.

# 02 / Producto inicial y diferenciación

Hipótesis: personas con poco tiempo que compran en línea y administran gastos cotidianos. Entrevistar 15–20 usuarios y elegir una necesidad recurrente: **compras recurrentes y pendientes personales con presupuesto y control explícito**.

| Capacidad | Primera versión | Prueba de utilidad |
|---|---|---|
| Chat en español mexicano | P0: texto, enlaces y adjuntos limitados | Pedir una compra sin aprender comandos. |
| Investigación y comparación | P0: fuentes, precio total y fecha | Comparar 2–3 opciones con envío y stock verificables. |
| Memoria personal | P0: editable y borrable | Talla, domicilio y preferencias sin mezclar personas. |
| Segundo plano | P0: VM propia, estado y cancelación | Continúa con app cerrada; recupera sin repetir compras. |
| Compra asistida | P0: 2–3 comercios habilitados | Cotización vigente y aprobación antes de pagar. |
| Dinero y tarjeta | P0 condicional: proveedor aprobado | Saldo confirmado, reserva y conciliación. |
| Postventa | P0: historial, pedido y ayuda | Distingue pago, pedido aceptado y entrega. |
| WhatsApp | P1 condicional: uso admitido | Canal autorizado y notificaciones conformes. |
| Correo, calendario y voz | P1: permisos mínimos; voz opcional | Acceso revocable; acciones importantes confirmadas. |
| Compras universales / finanzas | P2: evaluar después | Fuera de la promesa del MVP. |

## Diferenciadores que sí probaría

- Precios finales en pesos, domicilios mexicanos, disponibilidad local y factura cuando el comercio la ofrece.
- Transparencia: qué encontró, cuánto costará, qué permiso solicita, qué hizo y qué sigue pendiente.
- Postventa humana para tareas incompletas. Medir compras resueltas, no cantidad de mensajes.

Fuera del MVP: crédito, inversión, cripto, remesas, retiros, transferencias libres a terceros, productos regulados, viajes complejos y compras automáticas sin límites. Es una decisión de alcance, no una clasificación legal universal.

# 03 / Hermes como base: qué reutilizar

**Hermes Agent de Nous Research, no solamente los modelos Hermes.** Ofrece herramientas, memoria, automatizaciones, proveedores de modelos y API HTTP. Su licencia MIT permite uso comercial con conservación de avisos; revisar además licencias de dependencias, modelos y servicios. [S02–S03, S06]

| Opción | Aporta | Decisión propuesta |
|---|---|---|
| Hermes Agent | Asistente, memoria, herramientas y ejecución | Primera opción para piloto detrás de nuestra API. |
| LangGraph / Deep Agents | Flujos persistentes y controlados | Alternativa si Hermes falla en aislamiento, costo o recuperación. [S09] |
| Motor propio | Control de componentes | Posponer: repite trabajo antes de validar demanda. |
| Frontend sobre un LLM | Chat rápido de demostrar | No sustituye el sistema de compras. |

## Reutilizar sin transferirle toda la autoridad

- Memoria, planificación, búsqueda, lectura y conectores aprobados. Fijar versión/commit; probar actualizaciones.
- Nuestra API protege el motor; el usuario no recibe llaves administrativas. Probar ejecución, eventos y aprobaciones. [S06]
- Reglas de dinero, estados de pedido, consentimientos y permisos efectivos fuera del motor. Las skills no pueden cambiarlos.

## Hallazgo sobre perfiles

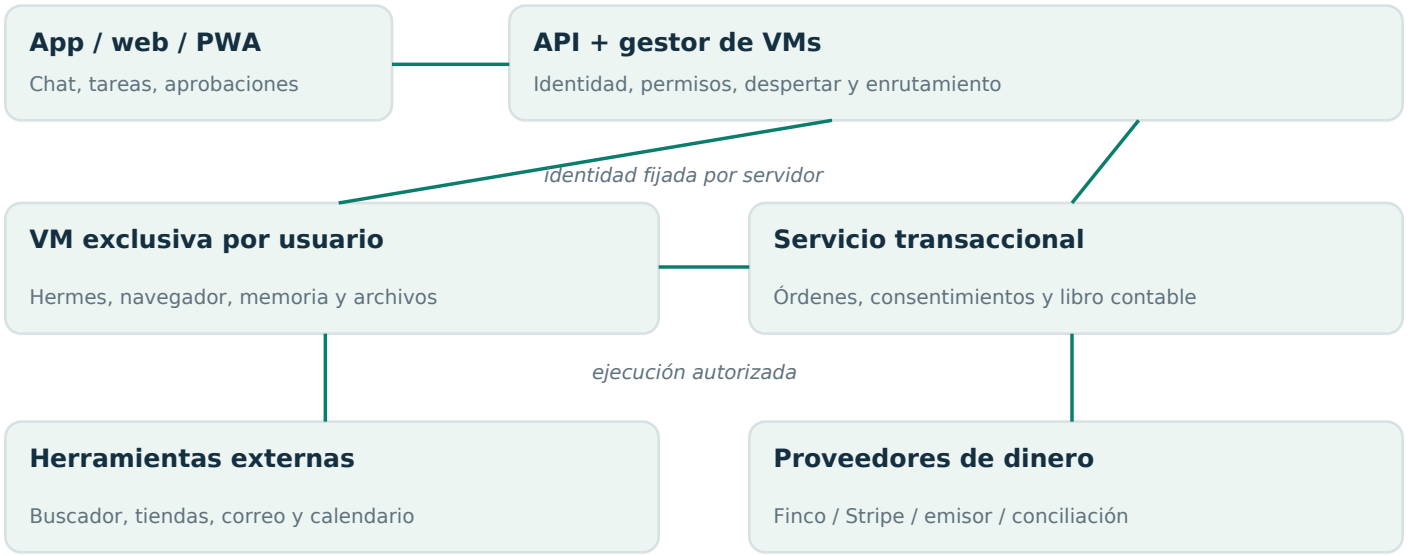
Los perfiles separan configuración y estado, pero la creación habitual puede copiar claves y compartir logins. Evitar herencia, asignar credenciales propias y comprobar aislamiento con dos usuarios. Cambiar el nombre del perfil no basta. [S04]

## Viabilidad en 10 días hábiles

Dos usuarios y dos VMs exclusivas con memoria, disco y navegador propios. Validar identidad, ausencia de credenciales cruzadas, compras autorizadas, recuperación, revocación y costo de 100 tareas. Si exige un fork profundo o no cierra accesos, cambiar el motor conservando VMs y contratos de herramientas.

**Hermes reduce trabajo del asistente. La plataforma de consumo y la operación financiera siguen siendo responsabilidad del producto.**

# 04 / Arquitectura y fuente de verdad




Diseño propuesto, no infraestructura instalada. WhatsApp entra por un adaptador separado si se admite el uso. Los pagos no dependen de ese canal.

| Componente | Responsabilidad y límite |
|---|---|
| API + gestor de VMs | Autentica, fija tenant_id/VM, aprovisiona, despierta y detiene. Colas y agenda viven fuera de VMs detenidas. |
| VM exclusiva | Hermes, disco cifrado, navegador/cookies y archivos propios. Identidad breve; sin llaves globales de dinero. Un contenedor compartido no cumple. |
| Servicio transaccional | Valida política, aprobación y fondos. Adaptadores Finco/emisor/comercio; estados durables. |
| Base operativa | Usuarios, tareas, cotizaciones, órdenes, consentimientos, eventos, auditoría y libro auxiliar; centavos y moneda explícita. |
| Proveedores externos | Fuente real de fondos, autorizaciones, capturas y pedidos. Saldo mostrado reconciliado con reportes. |
| Operación humana | Resuelve estados desconocidos; acceso mínimo, intervención registrada y doble control para ajustes. |

## Reglas de diseño

- El chat no acredita dinero; el modelo no confirma compras. El éxito viene de eventos firmados o consultas verificadas.
- Libro de doble partida si hay saldos y reservas: disponible, reservado y liquidado separados. Correcciones compensatorias, sin borrar historia.
- Una identidad por intención de compra compartida por reintentos, tareas y webhooks. Investigar un resultado incierto antes de volver a pagar. [S05–S06]

# 05 / Los tres flujos de dinero

## A. Cobrar nuestro servicio

**Usuario → Stripe Checkout/Billing → empresa.** Membresía o gestión autorizada; factura de servicio, cancelaciones, fallos y reembolsos. No mostrar esos ingresos como saldo de compra del usuario.

## B. Fondear la cuenta para compras

**Banco del usuario → CLABE asignada → cuenta contractual del titular.** SPEI solo si Finco lo habilita. Confirmar abono, ordenante, límites y devolución. Una CLABE virtual puede ser referencia de cobro, no prueba de cuenta individual a nombre del usuario.

## C. Pagar al comercio

**Autorización → reserva → tarjeta/token del emisor → comercio → pedido.** El emisor debe admitir compras asistidas por IA. Reglas por importe, plazo, comercio y reembolso. Registrar una tarjeta en Stripe no permite gastarla en otros sitios.

| Momento | Registro y control |
|---|---|
| Cotización | Variante, vendedor, moneda, total, envío, domicilio, devolución y vencimiento. |
| Aprobación | Identidad, cotización exacta, máximo, plazo y evidencia del consentimiento. |
| Reserva / ejecución | Reserva atómica, política y credencial limitada; sin doble gasto. |
| Resultado | Autorización ≠ captura ≠ pedido. IDs separados por sistema. |
| Fallo / incertidumbre | Si pudo cobrar: estado desconocido, consulta y conciliación. No liberar ni reintentar a ciegas. |
| Reembolso / disputa | Relacionado al pago original; distinguir devolución de contracargo y esperar confirmación. |

**Alternativa:** agente prepara carrito y usuario paga directamente al comercio. Prueba demanda antes de custodiar fondos. Connect sirve para vendedores incorporados; no incorpora automáticamente tiendas externas. [S14]

**Stripe para el servicio; SPEI y tarjeta mediante proveedor habilitado; pago directo al comercio cuando sea posible. Recargar un monedero exige revisión expresa del flujo y de Stripe. [S11, S18]**

# 06 / Qué pedirle a Finco

Finco permanece por confirmar. Faltan identidad legal, contrato y documentación. No atribuimos a Finco las capacidades públicas de Monato/Fincore encontradas durante la investigación.

| Bloque | Información y prueba requerida |
|---|---|
| Entidad y contrato | 1. Razón social/RFC y entidad por servicio. 2. Titular de fondos y CLABE. 3. Contrato para consumidores mexicanos y compras IA. 4. Subcontratación y responsabilidades. |
| Cumplimiento | 5. Responsable KYC y revisión manual. 6. Límites/documentos por nivel. 7. PLD/FT, listas y alertas. 8. Congelamiento, reclamaciones, cierre y devolución. |
| Cuenta y SPEI | 9. Cuenta individual o concentradora. 10. API saldo/reservas/reportes. 11. Entradas, salidas y devoluciones. 12. Firma, idempotencia, orden y consulta de eventos desconocidos. |
| Tarjetas | 13. Emisor, red, BIN, territorio y tipo. 14. E-commerce, 3DS e internacional. 15. Límites por operación/día/comercio/MCC. 16. Un uso, bloqueo, tokenización, captura diferida. |
| Liquidación y fraude | 17. Parciales, reversas, contracargos y tarjetas cerradas. 18. Responsabilidad, reservas, prefondo y negativo. 19. Tarifas y liquidación. 20. SLA, incidentes, sandbox y salida/migración. |

## Documentos que desbloquean implementación

- Contrato, anexos, matriz de responsabilidades, evidencia de entidad regulada según servicio y términos del usuario.
- OpenAPI/colección oficial, sandbox, catálogo de errores/eventos, credenciales y tarjetas de prueba; contacto técnico.
- Estado de cuenta y conciliación; evidencia de SPEI, autorización, captura, reversa y reembolso.

Verificar razón social y patrocinador en registros pertinentes. PES y SIPRES ayudan; marca y razón social pueden diferir, y un registro no prueba permiso del programa específico. [S26–S27]

**Para dinero real: demostrar compra y devolución completas, con titularidad y responsabilidad confirmadas por contrato.**

# 07 / Stripe: alcance y decisiones

| Producto / uso | Encaje para este proyecto |
|---|---|
| Checkout + Billing | Membresía y servicio propio en web; renovar, cancelar y reembolsar. |
| Bank Transfers | Cobros admitidos para cuentas mexicanas en MXN. Saldo de cobro no es cuenta general del usuario. [S13] |
| Connect | Solo plataforma de vendedores incorporados y flujo aprobado; quién cobra y responde por pérdidas. [S14] |
| Link para agentes | Soporte público US/Canadá; no dependencia del consumidor mexicano. [S10] |
| Issuing | No inferir emisión local por tener Payments; elegibilidad geográfica específica. [S15] |
| Recarga / pagos a terceros | Aprobación comercial antes de desarrollar; restricciones de valor almacenado y facilitación. [S11] |

## Información concreta para Stripe

- Diagrama de los tres flujos, jurisdicción, razón social, cliente, productos y vendedor contractual por compra.
- Indicar servicio, recarga, mandato o vendedores conectados; Finco/emisor, reservas y fraude.
- Pedir habilitación, límites, disputas, liquidación, monedas y aceptación expresa del caso. Activar cuenta no aprueba todas las variantes.

## Implicación económica

Tarjeta nacional publicada: **3.6% + MXN 3** antes de IVA. En MXN 1,000: MXN 39 base y MXN 45.24 con provisión de IVA de 16% sobre la comisión. No incluye Billing ni extras. [S12]

Si el margen hipotético de esa operación fuera MXN 50 y absorbieras el proceso, restan MXN 4.76 antes de IA, soporte, proveedor y fraude. Es ilustración, no margen observado.

Para membresía de MXN 1,499, el apéndice añade Billing 0.7%: comisión neta total MXN 67.457 por cargo. No aplicar esta tarifa al GMV pagado con Finco.

Webhooks firmados, deduplicados y reconsultados: no se garantiza orden y pueden repetirse. Idempotencia del proveedor más identidad persistente de nuestra compra. [S16–S17]

# 08 / Comercios, compra y postventa

El cuello de botella es dónde comprar con datos confiables y permiso contractual. No prometer Amazon, Mercado Libre, Walmart, Rappi u otros sin verificar su programa, API y permiso específico.

| Nivel | Implementación | Regla de lanzamiento |
|---|---|---|
| 1. API / convenio | Catálogo, stock, carrito, pedido, reembolso y eventos | Preferido; contrato y pruebas, vendedor identificado. |
| 2. Checkout preparado | Agente prepara; usuario completa el pago | Alternativa si no hay emisión o API transaccional. |
| 3. Navegador controlado | Sesión aislada, credencial limitada y pantalla | Solo dominios admitidos; 3DS/CAPTCHA con usuario, probar cambios UI. |

## Secuencia mínima

**Solicitud → opciones → cotización → aprobación → reserva → ejecución → pedido confirmado → seguimiento → entrega.** Ramas de vencimiento, rechazo, cancelación, desconocido, reversa, devolución y disputa.

- Comparar variante y costo total. Cambios fuera del alcance en precio, comercio, dirección o condiciones requieren nueva aprobación.
- Revalidar stock, entrega, devolución, garantía y factura. Mostrar vendedor y comisión de afiliación.
- Guardar pedido y pago separados. Pago exitoso sin pedido requiere investigación y postventa, no mensaje “comprado”.
- Cancelar en preparación detiene ejecución; tras compromiso externo es solicitud de cancelación/reembolso y debe explicarse.

## Cobertura inicial

Elegir 2–3 comercios de una categoría, más recordatorios y seguimiento. Priorizar API/convenio, recurrencia, devoluciones y soporte. Servicios solo con agregador contratado y reversas probadas.

ACP puede ayudar con participantes compatibles; no transforma todo sitio en integración ni resuelve elegibilidad de pagos. [S29]

# 09 / Requisitos para operar en México

Dictamen mexicano sobre el flujo concreto: obligaciones propias y delegadas. Usar proveedor no transfiere automáticamente toda responsabilidad.

| Área | Entregable antes de producción |
|---|---|
| Sociedad / fiscal | Razón social, RFC, representación, cuenta, facturación y contratos; marca/dominio y licencias. |
| Modelo financiero | Quién emite/administra fondos; régimen aplicable. Artículo 22 reserva actividades de fondos electrónicos a entidades autorizadas. [S18] |
| KYC / PLD-FT | Matriz por entidad: expediente, niveles, listas, monitoreo, alertas/reportes aplicables. No asumir que todo recae en la app. [S18] |
| Datos personales | Privacidad, finalidad, consentimiento, ARCO, conservación, proveedores/transferencias. Datos financieros/patrimoniales: consentimiento expreso salvo excepción. [S19] |
| Mandato / compras | Representación, límites, evidencia, proveedor del bien, errores y devoluciones. |
| Consumidor | Identidad, contacto, precio final, soporte y cancelación. Recurrencia informada; aviso de renovación al menos cinco días naturales donde aplique. [S20] |
| CFDI / impuestos | Quién factura bien y servicio; datos fiscales y PAC autorizado. Recibo Stripe no equivale a CFDI. [S21] |
| Tarjetas / PCI | Alcance con emisor/adquirente. Evitar PAN/CVV en chat, logs o memoria; no conservar CVV tras autorización. [S22] |
| Reclamaciones | Atención app y proveedor, conciliación, fraude, incidentes y plazos; UNE/CONDUSEF según régimen. |
| Canales / tiendas | Elegibilidad WhatsApp; reglas iOS/Android. Distinguir bienes físicos de membresía digital por storefront. [S24–S25] |

No presumir licencia propia, exención o protección de depósitos. Verificar entidad, contrato y producto ofrecido.

# 10 / Seguridad del agente y del dinero

**El modelo propone; un servicio determinista valida y ejecuta.** Páginas, correos, adjuntos y resultados son contenido no confiable aunque parezcan instrucciones. [S30]

| Control | Implementación requerida |
|---|---|
| Identidad | tenant_id fijado tras autenticación; sesiones/llaves no elegibles por texto. |
| Aislamiento | VM, disco cifrado, navegador, memoria y herramientas propios; probar backups, red y soporte. |
| Secretos | Bóveda por proveedor/entorno; credenciales breves y limitadas, sin llaves globales en Hermes. |
| Aprobación vinculada | Usuario, orden, versión, comercio, importe, moneda, alcance y vencimiento; impedir reutilización. |
| Gasto | Chequeo atómico en servidor por compra/día/comercio/saldo; cierre ante incertidumbre. |
| Navegación | Dominios y red restringidos; bloquear metadata cloud e internos. No evadir MFA/CAPTCHA. |
| Plugins / aprendizaje | Herramientas versionadas; skills proponen sin publicar código ni alterar controles financieros. |
| Acceso sensible | Reautenticación para credenciales, dirección/destinatario y riesgo; recuperación probada. |
| Auditoría | Firmas, anti-replay, deduplicación, trazas resistentes a cambios y redacción de datos. |
| Emergencia | Detener tareas/compras por usuario, proveedor o sistema; revocar. No simular deshacer pagos. |
| Operación interna | Roles mínimos, ajustes autorizados y soporte temporal justificado. |
| Ataques | Injection de producto/email, robo de sesión, mezcla de usuario, doble pago, enlaces y secretos. |

Aprobaciones generales de Hermes no sustituyen la compra específica. Probar aislamiento, límites y tareas desatendidas en la versión fijada. [S05]

# 11 / Experiencia, permisos y pantallas

| Pantalla | Contenido obligatorio |
|---|---|
| 1. Alta / acceso | Registro, adulto del MVP, términos, privacidad, contacto y recuperación. |
| 2. Conversación | Pedido natural, estado, fuentes y voz posterior. No pedir secretos por chat. |
| 3. Mis tareas | Objetivo, avance, bloqueo y cancelación; VM iniciando, trabajando, detenida o recuperando. |
| 4. Comparación | Variante, vendedor, total, envío y vigencia; límites de cobertura. |
| 5. Aprobar compra | Resumen y tope; aprobar/cambiar/rechazar separados; reautenticar según riesgo. |
| 6. Cuenta / tarjeta | Proveedor/titularidad correctos, disponible/reservado, movimientos, bloqueo y ayuda. |
| 7. Mis pedidos | Pedido, seguimiento, recibo, factura disponible, devolución/reclamación. |
| 8. Conexiones / memoria | Permisos por app; ver, editar, borrar preferencias; revocar y exportar. |
| 9. Plan / soporte | Precio, recurrencia, renovación, cancelación, historial y humano. |

## Ejemplo de aprobación

**Comprar 1 unidad de [producto/variante] a [vendedor], hasta MXN 1,249 total con envío, al domicilio terminado en [referencia], antes de [hora]. Si cambian las condiciones, consultarme. Aprobar / Cambiar / Cancelar.**

Servidor conserva campos y versión aceptada. Un “sí” ambiguo, una página o aprobación de otra conversación no autoriza.

## Niveles de permiso

**Lectura:** investigar y consultar. **Preparación:** carrito/borrador. **Ejecución:** pagar/enviar/publicar con alcance aprobado. **Recurrencia:** después, con máximo, frecuencia, vigencia y revocación explícitos.

Gmail: scopes mínimos; ciertos scopes exigen verificación y evaluación de seguridad si se almacenan/transmiten datos restringidos. Estimar ese proceso antes de depender de él. [S23]

# 12 / Backlog P0: plataforma y agente

P0 requerido para piloto; no todas las tareas requieren dinero real. Responsables por rol, sin asignación nominal.

| ID | Entregable verificable | Responsable |
|---|---|---|
| P00 | Usuario, caso, comercios, métricas y 15–20 entrevistas. | Producto |
| P01 | Flujo de fondos, titularidad y límites contractuales. | Legal + pagos |
| P02 | Sandbox, tarifas, eventos y programa de tarjetas. | Pagos |
| P03 | Versión/licencia Hermes y plan de actualizaciones. | Líder técnico |
| P04 | Dos VMs: aislamiento disco, memoria, sesión y red. | IA + seguridad |
| P05 | Registro, autenticación, recuperación y roles. | Backend |
| P06 | PWA: chat, historial, streaming y tareas. | Frontend |
| P07 | Adaptador Hermes privado, cuotas, cancelación y estado. | IA + backend |
| P08 | Búsqueda, comparación y lectura con evidencia. | IA |
| P09 | Memoria editable, borrable, exportable y procedencia. | IA + backend |
| P10 | Estados de compra, cotización y vencimiento. | Backend |
| P11 | Consentimiento autenticado por versión de cotización. | Backend + UX |
| P12 | Ejecución de pagos fuera del motor IA. | Pagos |
| P13 | Libro auxiliar y reservas atómicas si hay saldos. | Pagos |
| P14 | SPEI, identidad, límites, devolución, conciliación. | Pagos |
| P15 | Tarjeta, controles, 3DS, bloqueo y resultado final. | Pagos |
| P16 | 2–3 comercios con confirmación de pedido. | Integraciones |
| P17 | Webhooks firmados, deduplicación, colas y reconsulta. | Backend |
| P18 | Stripe servicio: cobro, renovación, baja y reembolso. | Pagos |
| P19 | Soporte de fallos, entrega, devolución y disputa. | Operación |
| P20 | Privacidad, términos, consentimiento y factura. | Legal + fiscal |
| P21 | Gestor VMs, agenda externa, cuotas, backup, restauración. | Infraestructura |
| P22 | Seguridad, fraude, concurrencia y costo. | QA + seguridad |
| P23 | Piloto por invitación, límites y revisión diaria. | Producto + ops |

P12–P15 dependen de P01–P02. P16 puede comenzar con pago directo del usuario. P18 no financia automáticamente P14.

# 13 / Backlog P1 y contratos técnicos

| ID | Después de validar piloto | Dependencia |
|---|---|---|
| P24 | WhatsApp oficial para uso elegible. | Confirmación de política |
| P25 | Plantillas y preferencias fuera de ventana. | P24 + adaptador |
| P26 | Gmail/calendario, mínimos y revocación. | OAuth |
| P27 | Audio, transcripción y respuesta con topes. | Consentimiento / costo |
| P28 | iOS/Android y publicación. | Cobro por tienda |
| P29 | Más comercios y pagos de servicios. | Acuerdo + devolución |
| P30 | Mandatos recurrentes acotados. | Fraude / postventa |
| P31 | Optimización IA y capacidad. | Trazas del piloto |
| P32 | Afiliación o vendedores integrados. | Contrato + margen |
| P33 | Continuidad y cambio de motor/proveedor. | Exportación + contratos |

## Contratos internos que fijar primero

- **Task:** usuario, objetivo, estado, plazo, presupuesto computacional, ejecución y motivo de bloqueo.
- **Quote:** comercio, variante, cantidad, total en centavos, moneda, envío, dirección autorizada, vigencia y versión.
- **Consent:** identidad, quote_id/versión, acción, límites, timestamp, expiración, nonce y evidencia. Valida servidor.
- **Payment / Order:** IDs separados; reserva, autorización, captura, pedido y reembolso relacionados.
- **Event:** proveedor, ID, fecha externa y recibida, tipo, objeto, firma validada y procesamiento.

## Herramientas estrechas

buscar_productos, crear_cotizacion, solicitar_aprobacion, consultar_pedido y solicitar_devolucion. Usuario efectivo desde autenticación. Ejecutar solo una orden aprobada, revalidando alcance en servidor.

Son contratos propuestos, no endpoints existentes; adaptar a APIs reales y versión fijada de Hermes.

# 14 / Roadmap: semanas 1 a 8

Semanas relativas con equipo disponible. Tiempos de terceros no garantizados.

| Etapa | Trabajo y entregables | Salida exigida |
|---|---|---|
| 1–2<br>Viabilidad | Entrevistas, dos VMs/Hermes/navegador, 100 tareas, CPU/RAM/arranque/costo. Preparar consultas Finco/Stripe/WhatsApp. | Motor y perfil VM decididos; vacíos de dinero documentados. Sin gasto real. |
| 3–4<br>Fundación | PWA, identidad, gestor usuario-VM, agenda externa, disco, recuperación, observabilidad; aprobación y pagos simulados. | Aislamiento; tarea sigue con app cerrada, despierta y cancela. |
| 5–6<br>Agente útil | Búsqueda, comparación y 2–3 flujos; carrito con pago del usuario; costo/calidad iniciales. | Demostración completa, variantes/precios verificables y usuarios invitados. |
| 7–8<br>Dinero sandbox | KYC, CLABE/tarjeta habilitados, libro, firmas, idempotencia, reversas y conciliación; Stripe servicio. | Ciclo dinero/pedido/reembolso y contratos antes de piloto real. |

## Ruta crítica

**Titularidad/contrato → sandbox → fondos → reserva/aprobación → compra → devolución → conciliación → piloto.** Interfaz lista no elimina estas dependencias.

## Puede avanzar sin Finco

- Experiencia, entrevistas, marca, Hermes aislado y memoria/costo.
- Comparación, recordatorios, seguimiento y checkout pagado por usuario.
- Órdenes, consentimiento, auditoría, simuladores y adaptadores.

**Si un proveedor tarda, iniciar investigación y compra asistida. No improvisar cuenta concentradora para sustituir permisos pendientes.**

# 15 / Roadmap: piloto y expansión

| Etapa | Trabajo y entregables | Salida exigida |
|---|---|---|
| 9–10<br>Pruebas completas | Saldo concurrente, caídas, pago sin pedido, precios, fraude, seguridad y restauración; manuales/escalamiento. | Sin críticos; conciliación y rollback probados. |
| 11–12<br>Piloto | 25–50 invitados, límites bajos, revisión diaria y compras reales solo con flujo aprobado. | Cada movimiento trazable; soporte y tareas completas. |
| 13–16<br>Estabilizar | 100–300 si cumplen metas; conversión, calidad, tiempos, costos, tarifas y antifraude. | Economía conocida antes de adquirir volumen. |
| 17–20<br>Canales | WhatsApp elegible/plantillas; OAuth; apps según prioridad y revisión. | Identidad, consentimiento y estado consistentes con web. |
| 21–24<br>Cobertura | Más comercios, categorías, acuerdos, recurrencias limitadas, capacidad y continuidad. | Solo expandir flujos con postventa y margen medidos. |

## WhatsApp es una decisión separada

Hermes tiene Cloud API y Baileys; Baileys emula WhatsApp Web y no se recomienda como base comercial. Cloud API tampoco autoriza un asistente generalista restringido. [S07–S08, S25]

Soporte/avisos requieren encaje Meta/BSP, consentimiento y plantillas. El antecedente de Hermes advierte plantillas fuera de 24 h no implementadas en ese adaptador: revisar versión y cubrir si se necesita. [S08]

## Móvil

PWA reduce dependencias. iOS trata distinto bienes físicos fuera de app y suscripción digital. Verificar storefront mexicano antes de usar Stripe para desbloquear funciones. [S24]

Finco, OAuth, Meta o tiendas pueden desplazar etapas. El presupuesto inicial cubre cuatro meses; semanas 17–24 requieren caja posterior según escala.

# 16 / Pruebas y criterios de lanzamiento

Metas propuestas, no resultados observados. Casos financieros con logs, estado del proveedor y libro auxiliar.

| Prueba | Resultado exigido |
|---|---|
| A pide datos de B | Sin acceso a memoria, archivos, órdenes, sesiones o secretos ajenos. |
| Injection en tienda | No amplía permisos, roba llaves ni cambia destinatario. |
| Sin aprobación / vencida | Bloqueo en servidor sin llamada válida de pago. |
| Cambia precio/domicilio/comercio | Nueva cotización/aprobación fuera del alcance. |
| Compras concurrentes | Reservas atómicas y saldo/límites respetados. |
| Webhook repetido/desordenado | Un efecto y estado conciliado. |
| Caída después de cobro | Desconocido y consulta; no segunda compra ciega. |
| Autorización sin pedido | Detectar y resolver reversa/postventa verificable. |
| Parcial / tarjeta cerrada | Conciliar devolución y ruta con emisor. |
| 3DS/CAPTCHA/sesión caducada | Intervención del usuario; no eludir. |
| Cancelar en ejecución | Distinguir antes/después del compromiso externo. |
| Revocar / cerrar | Detener nuevas acciones; retención y borrado documentados. |
| Reinicio agente/cola | Recuperar progreso sin doble gasto. |
| VM/backup/desastre | Agenda despierta VM correcta; restaurar datos propios y conciliar antes de pagar. |
| Ajuste por soporte | Permiso, evidencia y asiento corrector sin borrar historia. |

## Puertas de salida

- 100% de pagos con aprobación y trazabilidad; cero críticos conocidos; sin diferencias inexplicadas al cierre diario.
- Meta ≥90% de tareas del alcance sin operador en 100 casos; separar 3DS del usuario. No extrapolar a compras universales.
- Costo por tarea y soporte medidos; incidentes ensayados. Un gasto no autorizado detiene nuevas compras.

# 17 / Equipo e inversión actualizada

Sustituye el presupuesto preliminar de v1.1. Importes de planeación, no salarios observados.

| Rol | Responsabilidad | Dedicación propuesta |
|---|---|---|
| Fundador / PM | Producto, entrevistas, proveedores, prioridades | Fundador; remuneración no incluida |
| Líder técnico / backend | Arquitectura, identidad y revisión | 1 FTE × 4 meses |
| Ingeniería IA | Hermes, memoria, herramientas y evaluación | 1 FTE × 4 meses |
| Backend pagos | Adaptadores, reservas y conciliación | 1 FTE × 4 meses |
| Frontend | PWA, chat, aprobación, pedidos | 1 FTE × 4 meses |
| DevOps + QA | Infraestructura, pruebas y guardias | 0.5 FTE de cada rol × 4 meses |
| UX / diseño | Flujos y usabilidad | 0.5 FTE × 2 meses |
| Legal / fiscal / seguridad | Contratos y revisión especializada | Por entregable, sin duplicar operación |

## Base de inversión: cuatro meses con 25 VMs

| Partida | Monto MXN | Equivalente USD a 20 |
|---|---|---|
| Equipo de desarrollo | 1,660,000.00 | 83,000.00 |
| Legales, seguridad, equipo y otros únicos | 400,000.00 | 20,000.00 |
| Tecnología: cuatro meses de piloto | 111,706.49 | 5,585.32 |
| Subtotal | 2,171,706.49 | 108,585.32 |
| Contingencia 20% | 434,341.30 | 21,717.06 |
| **Inversión modelada** | **2,606,047.79** | **130,302.39** |

Incluye flota DO con backup, central y APIs; no se vuelve a sumar la flota. Excluye Finco, marketing, nómina del fundador, usuarios/fondos, KYC/OTP/cobro del piloto y operación humana adicional. El apéndice muestra el puente completo para agregarlos sin doble conteo.

Detener una VM DigitalOcean no reduce el cargo mientras exista. La política de inactividad tiene beneficios operativos; el ahorro económico requiere otro modelo de facturación, por ejemplo Fly validado.

# 18 / Modelo de negocio y métricas

## Ingresos por validar

- **Membresía:** cupo explícito de tareas; sin IA ilimitada sin límite económico.
- **Gestión:** tarifa visible antes de aprobar, separada del bien y envío.
- **Afiliación:** contrato y divulgación; comparación sin sesgo oculto.
- **Programa financiero:** no asumir interchange ni reparto sin contrato.

**Contribución = ingreso neto del servicio + comisiones contractuales − IA − VM/herramientas − pagos − soporte atribuible − fraude/devoluciones absorbidas.**

GMV no es ingreso del asistente si actúa como intermediario. Saldos de usuarios no financian servidores o nómina. Tratamiento contable depende del contrato.

| Métrica | Definición práctica |
|---|---|
| Activación | Usuarios con primera tarea útil / registrados del periodo. |
| Compra correcta | Variante, monto y destinatario autorizados con pedido / intentos autorizados. |
| Autonomía del alcance | Completadas sin operador / elegibles; separar ayuda del usuario como 3DS. |
| Costo por tarea | IA + herramientas + VM/infra variable + soporte atribuible / completadas. |
| Repetición 30 días | Activados que repiten / cohorte activada con 30 días observables. |
| Fraude / disputas | Pérdida neta y contracargos por cohorte; conteo y monto. |
| Conciliación | Monto y antigüedad de diferencias por proveedor; explicar saldos. |
| Tiempo a resolución | Mediana y p95 por tipo: compra, investigación y soporte. |

A MXN 1,499 IVA incluido, el escenario de 1,000 usuarios deja margen estrecho antes de Finco y marketing; ver sección 35. Es hipótesis de precio, no validación comercial.

# 19 / Primeros 10 días y decisiones pendientes

| Día | Resultado concreto propuesto |
|---|---|
| 1 | Segmento, tres tareas, decisiones, riesgos y fuentes. |
| 2 | Preparar reunión Finco: 20 puntos de sección 6 y cotización completa. |
| 3 | Dossier Stripe y elegibilidad WhatsApp; sin recargas improvisadas. |
| 4 | Fijar Hermes; dos VMs y discos/credenciales separados. |
| 5 | Prototipo de cotización, aprobación, tarea y pedido; cinco entrevistas. |
| 6 | Estados, consentimiento, herramientas y simulador de pagos. |
| 7 | Aislamiento, injection, revocación y cancelación. |
| 8 | Parada/arranque, agenda, duplicados y pago desconocido. |
| 9 | Lote de tareas; costos, limitaciones y completar entrevistas. |
| 10 | Decidir motor, API, alcance, equipo y presupuesto; priorizar backlog. |

## Decisiones pendientes, en orden

- **Finco:** identidad legal, programa, titularidad, emisor y API; integración provisional hasta documentarlos.
- **Cliente/categoría:** tarea mejor resuelta, comercios y ciudades iniciales.
- **Rol:** mandatario, plataforma o vendedor; factura, devolución y fraude.
- **Canales:** PWA primero; elegibilidad WhatsApp antes de prometer generalista.
- **Capacidad:** equipo, inversión, riesgo, límites y soporte fuera de horario.

Proveedor demorado → compra asistida. Hermes difícil de aislar → motor alternativo. Sin API comercio → checkout del usuario. Costo alto → límites. WhatsApp no elegible → canal propio. Diferencias contables o gasto indebido → detener compras.

**Este encargo entrega investigación y PDF, no prototipo. Próximo hito de implementación propuesto: dos VMs exclusivas, Hermes, navegador y compra simulada con aprobación; pagos reales solo tras programa aprobado y devolución/conciliación probadas.**

# 20 / Una VM exclusiva por usuario

Requisito confirmado; política de encendido propuesta y sujeta al perfil de uso

**Cada persona tiene su VM persistente: Hermes, navegador, disco cifrado, memoria, cookies y archivos propios. Trabaja con la app cerrada. El runtime personal no se comparte con otros usuarios.**

| Componente | Diseño propuesto |
|---|---|
| Asignación | Relación usuario-VM validada por servidor. Imagen común; después disco y credenciales exclusivos. |
| Capacidad | Probar Linux 2 vCPU/4 GB; comparar 4 vCPU/8 GB con navegador. Tamaños por medir, IA por API. |
| Continuidad | VM activa mientras trabaja; cerrar app no cancela. Límites de tiempo y presupuesto. |
| Inactividad | Persistir y detener sin trabajo. Agenda, colas y webhooks centrales despiertan la VM correcta. |
| Parada segura | No detener con pago sin resolver. Al reanudar, consultar proveedor antes de reintentar; sesiones pueden caducar. |
| Disponibilidad | Creando, iniciando, lista, trabajando, detenida, recuperando/error. Medir arranque y fijar SLA. |
| Seguridad | Red privada, identidad breve, egreso limitado, bloqueo entre VMs; parches y snapshots/recuperación probados. |

## Persistencia y costo

Persistencia conserva archivos, memoria y estado; no exige RAM siempre viva ni hardware físico reservado. Hibernación de RAM es opcional y limitada por proveedor. EC2 detenido conserva cargos de discos y recursos. [S31–S32]

**Flota = Σ(cómputo facturable + disco + copias + red/IP).** El cómputo facturable depende del proveedor: DO cobra también apagada; Fly puede cobrar horas activas y rootfs detenido. Modelos y central se suman por separado.

Pruebas: alta idempotente, aislamiento A/B, despertar programado, caída durante pago, impedir doble arranque, recuperar snapshot y baja con borrado/retención. Una VM detenida no trabaja: agenda siempre externa.

# 21 / Presupuesto: alcance y supuestos

Apéndice nuevo | USD y MXN por mes, salvo indicación | Corte de investigación recibido: 11/11/2026

Los escenarios son presupuestos de una arquitectura aún no desplegada. No prueban capacidad, demanda, calidad ni elegibilidad comercial. Cada total excluye partidas Q pendientes y muestra provisiones por separado.

| Clave | Significado | Tratamiento |
|---|---|---|
| P | Precio público del antecedente recibido | Tarifa con fuente; revalidar fecha, región y contrato. |
| E | Estimación de cantidad o personal | Consumo, FTE y configuración supuestos; no medición. |
| R | Provisión presupuestaria | Bolsa para exceso, riesgo o contingencia; no tarifa. |
| Q | Cotización / habilitación pendiente | No vale cero y no está dentro de los totales cerrados. |

| Entrada | 25 usuarios | 100 usuarios | 1,000 usuarios |
|---|---|---|---|
| Usuarios activos del mes | 25 | 100 | 1,000 |
| Altas nuevas con KYC | 25 | 30 | 150 |
| Tareas por usuario / mes | 20 | 20 | 20 |
| Entrada por tarea, todos los pasos | 150,000 tokens | 150,000 tokens | 150,000 tokens |
| Salida por tarea, incl. razonamiento | 12,000 tokens | 12,000 tokens | 12,000 tokens |
| Búsquedas por tarea | 3 | 3 | 3 |
| Correo por usuario / mes | 30 | 30 | 30 |
| OTP exitosos por usuario / mes | 2 | 2 | 2 |
| Intentos SMS por OTP | 1.2 | 1.2 | 1.2 |
| Cargo propio por usuario / mes | MXN 1,499 | MXN 1,499 | MXN 1,499 |
| CFDI por usuario / mes | 1 | 1 | 1 |

## Moneda, impuestos y caja

**FX de planeación: 20 MXN/USD**, no tipo de cambio actual. El antecedente Banxico reporta FIX determinado el 10/11 de 18.6678; el 11/11 figuraba N/E. Usar 20 agrega 7.14% de colchón cambiario. Sensibilidad a 18.6678 / 20 / 22. [C25]

IVA 16% es una **provisión de caja** sobre proveedores normalizados a neto, no dictamen de importación de servicios, retenciones o acreditamiento. Facturapi ya incluye IVA y no se vuelve a gravar. Personal/bolsas únicas se modelan como costo total sin otra capa de IVA; confirmar cada contratación. ISR, nómina adicional no cubierta, retenciones y fiscalidad efectiva: revisión con contador.

# 22 / Inversión: equipo de desarrollo

E = costo total mensual de planeación, no sueldo observado ni cotización laboral [C26–C27]

| Rol | FTE | MXN / mes por FTE | Meses | Total MXN |
|---|---|---|---|---|
| Líder técnico / backend | 1 | 100,000.00 | 4 | 400,000.00 |
| Ingeniería de IA | 1 | 90,000.00 | 4 | 360,000.00 |
| Backend de pagos | 1 | 85,000.00 | 4 | 340,000.00 |
| Frontend | 1 | 65,000.00 | 4 | 260,000.00 |
| DevOps | 0.5 | 80,000.00 | 4 | 160,000.00 |
| QA | 0.5 | 45,000.00 | 4 | 90,000.00 |
| UX / diseño | 0.5 | 50,000.00 | 2 | 50,000.00 |
| **Total desarrollo** | | | | **1,660,000.00** |

FTE significa equivalente de tiempo completo: 0.5 por cuatro meses son dos meses-persona. Son 21 meses-persona en total; UX participa solo dos meses a media dedicación. Las cifras incluyen una bolsa cargada supuesta; no se derivaron tablas salariales verificables de Hays o CodersLink.

## Qué sí cubre y qué queda fuera

- Cuatro meses de implementación PWA, agente, backend transaccional, plataforma VM, QA e integración condicionada. El desarrollo no supone construir un modelo fundacional.
- El fundador/PM se considera aportación propia: remuneración adicional Q. Si no ejecuta producto/proveedores, añadir ese rol.
- Semanas 17–24: se presupuestan después con operación y ampliaciones; no llamar al monto de cuatro meses financiamiento de seis meses completos.
- Soporte de usuarios durante piloto no está oculto en desarrollo. Asignar quién lo hará y sumar solo horas/personas no cubiertas por estos FTE.

## Compra de equipo

MXN 100,000 para cuatro laptops a MXN 25,000 (E), incluidos en únicos. Es un supuesto de inventario: si los colaboradores aportan equipos, sustituir por política/arrendamiento; si todos necesitan uno, cuatro pueden no bastar. No hay cotización de marca ni hardware contratado.

**No sumar la nómina mensual de operación al equipo de desarrollo para las mismas personas y meses. Los presupuestos describen etapas distintas; cualquier solapamiento necesita una asignación explícita.**

# 23 / Inversión: únicos y caja de arranque

| Partida única (E/R) | MXN | USD equivalente |
|---|---|---|
| Constitución / notario / trámites | 30,000.00 | 1,500.00 |
| Contratos comerciales y financieros | 60,000.00 | 3,000.00 |
| Privacidad y acuerdos de tratamiento | 30,000.00 | 1,500.00 |
| Configuración fiscal / contable | 15,000.00 | 750.00 |
| Pentest y revisión de pagos | 90,000.00 | 4,500.00 |
| Provisión evaluación OAuth restringido | 60,000.00 | 3,000.00 |
| Marca / identidad inicial | 15,000.00 | 750.00 |
| 4 equipos × MXN 25,000 | 100,000.00 | 5,000.00 |
| **Total únicos** | **400,000.00** | 20,000.00 |

Legal, pentest y OAuth son provisiones de planeación, no precios publicados. La evaluación OAuth puede no aplicar o superar la bolsa; solo ejecutar si se eligen scopes restringidos. Revisiones recurrentes futuras se cotizan aparte.

| Puente de inversión | Fórmula | MXN |
|---|---|---|
| Tecnología de cuatro meses | 4 × 27,926.62 | 111,706.49 |
| Subtotal | Equipo + únicos + tecnología | 2,171,706.49 |
| Contingencia de proyecto | 20% del subtotal | 434,341.30 |
| **Base modelada** | Subtotal × 1.20 | **2,606,047.79** |
| KYC + OTP + cobro propio del piloto | 4 × (proveedores − tecnología) | 19,741.83 |
| Riesgo piloto: bolsa separada | 4 × MXN 250 | 1,000.00 |

Para un piloto cobrado cuatro meses con 25 usuarios, la base más KYC/OTP/cobro y bolsa de riesgo es **MXN 2,626,789.62**, antes de personal de piloto no cubierto, Finco y extras Q. KYC 25 altas/mes en este puente es conservador: si se verifica una sola cohorte, sustituir el consumo por mes, sin ignorar mínimos contractuales.

Cuentas/tarjetas, reservas contractuales, tiendas, voz, WhatsApp, marketing, expansión de meses 5–6 y sueldos del fundador no entran en esta base. No se usan depósitos de clientes como capital de trabajo.

# 24 / VM propia: costo y alternativas

Baseline DigitalOcean; Fly como alternativa a validar, sin sustituir el requisito de VM exclusiva [C01–C02, C28–C29]

| Unidad por usuario | Tarifa USD | Cantidad | USD / mes |
|---|---|---|---|
| DO Basic regular: 2 vCPU, 4 GiB, 80 GiB | 24 / mes | 1 VM | 24.00 |
| Backup diario DO, retención 7 días | 30% VM | 1 cobertura | 7.20 |
| **Total baseline** | | 1 usuario | **31.20** |
| Perfil mayor: 4 vCPU, 8 GiB, 160 GiB | 48 × 1.30 | Alternativa | 62.40 |
| Perfil pequeño: 1 vCPU, 2 GiB | 12 × 1.30 | Solo experimentar | 15.60 |

DO factura también cuando la VM está apagada mientras exista. La facturación por segundo con tope mensual no elimina ese cargo. Los 80 GiB están incluidos: no sumarlos otra vez. Backup diario no equivale a recuperación instantánea ni sustituye restauraciones probadas. [C28]

| Flota DO + backup | 25 | 100 | 1,000 |
|---|---|---|---|
| USD netos / mes | 780.00 | 3,120.00 | 31,200.00 |
| MXN a 20, antes de provisión IVA | 15,600.00 | 62,400.00 | 624,000.00 |

## Fly: 60 horas activas por usuario al mes, hipótesis

IAD/EWR, mes de 720 h. Cómputo 2×/2 GB USD 13.39 + 2 GB adicionales × 6 = **25.39** para 4 GB continuo; tamaño derivado por validar en proveedor. 20 GB volumen, 2 GB rootfs detenido, 20 GB snapshot y 10 GB egreso. [C29]

**25.39/720 × 60 + 20×0.15 + 2×0.15×660/720 + 20×0.08 + 10×0.02 = USD 7.1908/usuario/mes.** A 720 h: USD 30.19. No se presume crédito de 10 GB snapshots por organización ni descuentos.

Flotas Fly 60 h: USD 179.77 / 719.08 / 7,190.83. Disco de 20 GB no es equivalente al de 80 GB de DO y la cobertura de snapshot debe probarse. IPv4 dedicado opcional USD 2/mes; static-egress USD 0.005/h cuando se use. No sumar ambos sin necesidad ni trasladar ahorro a DO.

# 25 / Plataforma central: cómputo y datos

Tarifas P × cantidades E. La configuración no es un benchmark de capacidad ni una garantía HA.

| Partida / configuración | 25 usuarios USD | 100 usuarios USD | 1,000 usuarios USD |
|---|---|---|---|
| API/gestor: 1×48 / 1×48 / 3×48 | 48.00 | 48.00 | 144.00 |
| Workers: 1×12 / 1×48 / 3×48 | 12.00 | 48.00 | 144.00 |
| Staging: 1×12 / 1×24 / 1×24 | 12.00 | 24.00 | 24.00 |
| Backup: 30% cómputo anterior | 21.60 | 36.00 | 93.60 |
| PostgreSQL + disco extra | 36.90 | 283.00 | 306.00 |
| Valkey: 1×15 / 1×30 / 2×30 | 15.00 | 30.00 | 60.00 |
| Balanceador: 1×12 / 1×12 / 2×12 | 12.00 | 12.00 | 24.00 |
| Spaces: base 5 / 5 / 5+250×.02 | 5.00 | 5.00 | 10.00 |

## Base de datos y cambio importante de planes

**25:** PostgreSQL Standard 2 GB, 1 nodo × USD 30.45 + 30 GiB adicionales × 0.215 = **36.90**. No tiene standby ni HA. [C03]

**100:** 2 nodos Advanced × 130 + 2 × 100 GiB extra × 0.115 = **283**. **1,000:** 2 × 130 + 2 × 200 GiB extra × 0.115 = **306**. Almacenamiento extra por nodo, además del incluido. El antecedente documenta que nuevas cuentas desde 15/10/2026 no añaden standby a Standard. [C03]

Advanced desde USD 130/nodo es tarifa inicial, no confirmación de que el tamaño menor resista 1,000 usuarios, conexiones, IOPS o todo el historial. Verificar topología, capacidad, restauración y SLA. La API de 100 usuarios sigue siendo un nodo: HA de DB no vuelve redundante la plataforma completa.

## Archivos, red y colas

Spaces USD 5 incluye 250 GiB y 1 TiB egreso; extra USD .02/GiB storage y .01/GiB egreso. El escenario grande supone 500 GiB totales: USD 10. No duplica discos personales ni snapshots. [C06]

Valkey USD 15/1 GB o 30/2 GB; en 1,000 se provisionan dos instancias de USD 30, no se afirma replicación automática ni HA. Agenda durable y recuperación del backlog deben diseñarse. Red extra se mantiene en provisión separada para excesos de transferencia/cruces. [C04–C05]

# 26 / Herramientas centrales y secretos

Costos recurrentes de la plataforma, separados de la flota personal [C07–C13]

| Partida / cantidad | 25 USD | 100 USD | 1,000 USD |
|---|---|---|---|
| Cloudflare Pro / Pro / Business, mensual | 25.00 | 25.00 | 250.00 |
| Sentry Team / Team / Business, mensual | 29.00 | 29.00 | 89.00 |
| Resend Pro: USD 20, hasta 50k emails | 20.00 | 20.00 | 20.00 |
| GitHub Team: 5 / 5 / 10 × USD 4 | 20.00 | 20.00 | 40.00 |
| Workspace flexible: 5 / 5 / 10 × USD 8.40 | 42.00 | 42.00 | 84.00 |
| Dominio .com: renovación 19.98/año ÷ 12 | 1.665 | 1.665 | 1.665 |
| R: CI/CD adicional | 10.00 | 20.00 | 60.00 |
| R: logs/trazas adicionales | 15.00 | 30.00 | 100.00 |
| R: red / tráfico cruzado | 25.00 | 50.00 | 150.00 |
| **Total central, incl. sección 25** | 350.165 | 723.665 | 1,600.265 |

Cloudflare: USD 25/250 mes o 20/200 al comprometer año; usamos mensual. Sentry: USD 29/89 mensual o 26/80 anual. No se suma otro hosting para la PWA si vive en las APIs ya incluidas. Dominio es referencia de renovación, sin disponibilidad ni precio .mx verificados.

## Bóveda: provisión conservadora por secreto

AWS Secrets Manager: USD .40/secreto/mes + .05 por 10,000 consultas. Supuesto **20 + 3N** secretos y 30 lecturas por secreto/mes. Fórmula **(20+3N)×(.40 + 30×.05/10,000)**. [C13]

| N usuarios | Secretos | Consultas / mes | USD / mes |
|---|---|---|---|
| 25 | 95 | 2850 | 38.01425 |
| 100 | 320 | 9600 | 128.04800 |
| 1000 | 3020 | 90600 | 1,208.45300 |

Los secretos son OAuth y credenciales personales/centrales, no copias adicionales de la misma llave global por VM. Un broker de inferencia mantiene llaves globales fuera de la VM. Envelope encryption puede reducir el costo por secreto, pero agrega KMS, rotación y diseño; no se supone gratis ni se descuenta todavía.

# 27 / IA: consumo y costo por tarea

Supuesto de carga, no medición. Precios por millón de tokens; no llamadas pagadas [M01–M04, M10]

**20 tareas × 150k entrada = 3M entrada/usuario/mes.** Los 150k suman todas las llamadas y relecturas, incluidas imágenes facturables tras su tokenización. **20 × 12k salida = .24M salida**, incluido razonamiento facturable. No suponer que 150k es un prompt único: excede el contexto de GPT-OSS si se envía sin dividir.

| Modelo / proveedor | USD / 1M entrada | USD / 1M salida | USD / usuario / mes |
|---|---|---|---|
| GPT-OSS-120B / Groq | .15 | .60 | 0.5940 |
| GPT-OSS-20B / Groq | .075 | .30 | 0.2970 |
| Qwen3.6-35B-A3B / DeepInfra | .10 | .95 | 0.5280 |
| GPT-OSS-120B / Cerebras Developer | .35 | .75 | 1.2300 |
| GPT 6.1 Sol / OpenAI (referencia cerrada) | 2.00 | 10.00 | 8.4000 |
| GPT 6 Luna / OpenAI (referencia cerrada) | .10 | .50 | .4200 |
| GPT 6 Astra / OpenAI (referencia cerrada) | 10.00 | 50.00 | 42.0000 |
| **Mezcla 80% Groq120B + 20% Qwen** | **.14** | **.67** | **.5808** |

La mezcla es por tokens de entrada y salida, no por número de usuarios. Supone 20% del consumo total atendido por Qwen, incluido visual. Reintentos y gasto adicional fuera de esta bolsa elevarían el costo. Son comparaciones de precio con la misma carga numérica, **no calidad ni tokenización equivalentes**.

| Partida mensual | 25 usuarios | 100 usuarios | 1,000 usuarios |
|---|---|---|---|
| Inferencia de mezcla, USD | 14.52 | 58.08 | 580.80 |
| Brave: 60 búsquedas × .005 USD | 7.50 | 30.00 | 300.00 |
| Tokens entrada / salida de flota | 75M / 6M | 300M / 24M | 3,000M / 240M |

Brave USD 5/1,000 búsquedas; ignoramos crédito mensual USD 5 para conservadurismo. No sumamos OpenAI Web Search (USD 10/1,000 + tokens) al mismo trabajo. DeepInfra cached-input .10; Priority 1.5× y Flex .8× son alternativas, no cargos ya incluidos. [C14, M02, M10]

# 28 / Modelos abiertos y APIs rápidas

TPS = tokens de salida/segundo publicados por proveedor; no benchmark ejecutado ni SLA

| Opción | Velocidad / tarifa publicada | Encaje y límite |
|---|---|---|
| GPT-OSS-120B / Groq | 500 TPS; USD .15/.60 por 1M entrada/salida. Producción. | Primera prueba de texto y tools; Apache 2.0, 117B/5.1B activos. No visión. [M03, M06, M11] |
| GPT-OSS-20B / Groq | 1,000 TPS; USD .075/.30. Producción. | Evaluar tareas sencillas; mayor TPS no prueba calidad equivalente. [M03] |
| GPT-OSS-120B / Cerebras | ~3,000 TPS; USD .35/.75 en Developer. | Candidato de máxima velocidad; Developer para evaluar/desarrollar, producción Enterprise Q. [M04] |
| Qwen3.6-35B-A3B / DeepInfra | USD .10/.95, FP8; sin garantía TPS publicada en el antecedente. | Alternativa visual: 35B/3B activos, Apache 2.0, tools, JSON e imágenes; 262,144 contexto. [M01–M02] |
| Qwen3.8-27B (no baseline) | Groq preview: 450 TPS, .80/4.00; Cerebras ~1,850 TPS, .99/1.49. | Preview no elegido para producción. Verificar licencia/soporte antes de considerarlo. [M03–M04] |

## Por qué empezar con Groq y no comprar GPU

Bajo la carga supuesta, GPT-OSS-120B cuesta USD .594/usuario/mes; 1,000 usuarios son USD 594. El costo de GPU 24/7 para el mismo modelo es mayor antes de ingeniería. Groq reúne tarifa baja y estado de producción documentado; Cerebras puede ser más rápido según su publicación, pero requiere cotización Enterprise y medición propia.

GPT-OSS exige formato Harmony correcto en autohosting; la API compatible debe probarse con el parser/tool-calling de Hermes y manejo de razonamiento. Compatibilidad mayoritaria con OpenAI no garantiza igualdad de todos los campos/endpoints. No pasar claves globales a VMs. [M07, M11]

Qwen permite inspeccionar pantallas; MoE con 3B activos no implica que solo 3B pesos ocupen VRAM. Elegir por pruebas en español mexicano, tool accuracy y rechazo de inyecciones. Ninguna licencia de pesos garantiza por sí sola seguridad, no entrenamiento con datos o residencia. Revisar contratos de cada API.

# 29 / API frente a GPU alojada

Una capa de inferencia común; nunca una GPU por usuario. Datos y sesiones aislados por tenant.

| GPU Runpod Secure Cloud | VRAM | USD / h | Uso de referencia |
|---|---|---|---|
| A40 / RTX A6000 | 48 GB | .59 | Alternativa a medir; rendimiento/compatibilidad no equivalentes. |
| L40S | 48 GB | 1.09 | Qwen FP8/4-bit con contexto acotado: hipótesis. |
| A100 PCIe | 80 GB | 1.79 | Alternativa OSS; validar kernels, memoria y velocidad. |
| H100 PCIe | 80 GB | 2.89 | Base comparativa GPT-OSS-120B. |
| H100 SXM | 80 GB | 3.99 | Otra interconexión/perfil; sin TPS medidos. |

Tarifas del antecedente Runpod actualizado 09/11, no Community. Network storage <1 TB: USD .07/GB/mes. Modelo 100 GB = USD 7. Volume local corriendo .10/GB/mes, detenido .20; container disk .10: alternativas que no se suman todas automáticamente. Scratch, egreso o capacidad adicional: Q según consumo. [M08]

| Alternativa de inferencia | Hardware USD / mes | + operación USD | Umbral usuarios |
|---|---|---|---|
| Qwen L40S, 730 h + 100 GB | 802.70 | 1,202.70 | 1,520.3 / 2,277.8 |
| OSS120B H100 PCIe, igual disco | 2,116.70 | 2,516.70 | 3,563.5 / 4,236.9 |

Umbral = costo fijo / costo API por usuario (hardware solo / con operación). Ingeniería: 10 h × MXN 800 = MXN 8,000 = USD 400/mes (E), adicional solo si no la cubre el equipo operativo. HA de dos réplicas ≈ 2× cómputo, no necesariamente 2× todo el storage; añadir balanceo y soporte.

**El umbral no demuestra capacidad.** En Qwen, ~1,520 usuarios generan ~4,925M tokens totales/mes: ~1,874 tokens/s agregados en promedio a 730 h. OSS, ~3,563 usuarios: ~4,393 tokens/s agregados. Entrada y salida tienen costos de cómputo distintos; prefill, concurrencia y picos mandan. Una GPU puede no servir ese volumen con la latencia deseada.

OSS120B MXFP4 documenta caber en 80 GB; eso no garantiza contexto/concurrencia libres. Qwen 48 GB es por validar. No extrapolar 3,000 TPS de Cerebras a H100. Modal serverless queda como alternativa Q sin una tarifa fija verificada en este encargo. [M09, M11]

# 30 / Velocidad que importa al usuario

Protocolo propuesto; no ejecutado. Los límites TPM/RPM no miden generación TPS.

| Medida | Qué significa | Cómo decidir |
|---|---|---|
| TPS de generación | Tokens de salida por segundo durante decode. | Medir p50/p95 por respuesta, herramientas y razonamiento; conservar definición del proveedor. |
| TTFT | Tiempo hasta primer token desde solicitud. | Incluye cola, red y prefill; no está garantizado por cifra TPS. |
| Primera herramienta | Tiempo hasta argumentos completos, válidos y útiles. | Más relevante que primer texto si se debe iniciar una actividad. |
| Tiempo total de tarea | VM + planificación + navegación + aprobaciones + tools. | Medir p50/p95 de tareas equivalentes, incluyendo recuperación. |
| TPM / RPM | Cuota de volumen por minuto, no velocidad de un stream. | Groq Developer publica 250k TPM / 1,000 RPM para OSS; verificar tier y negociar picos. [M03] |

Con 12k tokens de salida, decode ideal a 500 / 1,000 / 3,000 TPS equivale a 24 / 12 / 4 segundos. **No es duración de una tarea:** faltan TTFT de cada paso, red, herramientas, permisos y páginas; TPS publicados pueden usar otra carga.

## Prueba de aceptación sugerida

- Un mismo lote de 100 tareas sin dinero real: comparación, navegación visual, memoria, lectura de correo simulado y tools con JSON. Español mexicano y datos sintéticos.
- Concurrencia 1, 5 y 20; p50/p95 TTFT, primera herramienta, TPS y tiempo total. Registrar errores, tokens, costo y llamadas mal formadas; fijar región y parámetros.
- Comparar Groq120B, Groq20B, Cerebras120B de evaluación y Qwen visual. Repetir según variabilidad; no declarar ganador por una sola respuesta rápida.
- Metas propuestas para tareas cortas: primera herramienta p95 ≤3 s y TTFT p95 ≤1.5 s; son criterios iniciales por probar, no promesas. Calidad/seguridad tienen veto.

A 1,000 usuarios la carga mensual suma 3,240M tokens: ~75,000/min de media a 30 días. Si 20% cae en un pico de 2 h, son 5.4M/min, muy por encima de 250k. Cerebras estima cuota incluyendo max_completion_tokens: no reservar máximos innecesarios. Colas, límites, presupuesto y tier contratado son obligatorios. [M05]

# 31 / Correo, OTP, KYC y facturación

Consumibles y mínimos mensuales. KYC externo es alternativa condicional a lo que incluya Finco.

| Servicio / fórmula | 25 usuarios | 100 usuarios | 1,000 usuarios |
|---|---|---|---|
| Resend: 30 emails × N | 750 emails | 3,000 emails | 30,000 emails |
| Resend Pro, USD netos | 20.00 | 20.00 | 20.00 |
| KYC nuevos: 25 / 30 / 150 | 25 | 30 | 150 |
| Veriff Plus: max(99,1.39×altas) + .64×altas, USD | 115.00 | 118.20 | 304.50 |
| Verify: 2 OTP exitosos × .05 × N, USD | 2.50 | 10.00 | 100.00 |
| SMS MX: 2.4 intentos × .1819 × N, USD | 10.9140 | 43.6560 | 436.5600 |
| **OTP total USD (.53656×N)** | 13.4140 | 53.6560 | 536.5600 |
| CFDI: 299 + .60×N, MXN con IVA | 314.00 | 359.00 | 899.00 |

**Correo.** Pro 50k emails a USD 20; exceso .90/1,000. Free 3k con 100/día no se asume para producción. Ya está dentro de central: no sumarlo de nuevo en totales. [C09]

**KYC.** Veriff Essential .80/check mínimo 49; Plus 1.39 mínimo 99; Premium 1.89 mínimo 209. AML addon .64/verificación; se eligió Plus+AML por provisión. Finco puede incluir KYC: en tal caso retirar esta alternativa, no pagar ambos por la misma alta. Rechazos, reverificaciones, revisiones manuales y monitoreo continuo: Q. No extrapolar .09 de ongoing monitoring sin confirmar unidad/periodicidad. [C16]

**OTP.** Verify .05 por éxito más SMS México .1819 por segmento saliente; entrante .02 no usado en baseline. 1.2 intentos por OTP y un segmento por intento son supuestos; mensajes largos, renta de número, carrier fees, fraude y canal alternativo pueden cambiarlo. No usar tarifa SMS de EE. UU. [C17–C18]

**Facturapi.** MXN 299/mes + .60 por CFDI con IVA incluido: se divide entre 1.16 al normalizar neto y se deja bruto una sola vez en caja. Catálogos, cancelaciones, complementos y operación contable fuera de alcance deben validarse con PAC/contador. [C15]

# 32 / Cobro del servicio, disputas y reservas

Tarifas sobre nuestra membresía; no sobre el GMV comprado mediante Finco [S12, C19, C30]

Membresía de prueba **MXN 1,499 IVA incluido**, un cargo nacional por usuario al mes. Payments 3.6% + MXN 3 y Billing adicional 0.7% del volumen: **f = (.036+.007)×1,499 + 3 = MXN 67.457 netos**, MXN 78.25012 con provisión de IVA.

| Concepto mensual | 25 usuarios MXN | 100 usuarios MXN | 1,000 usuarios MXN |
|---|---|---|---|
| Volumen cobrado propio (con IVA) | 37,475.00 | 149,900.00 | 1,499,000.00 |
| Payments + Billing, comisión neta | 1,686.43 | 6,745.70 | 67,457.00 |
| Comisión con provisión IVA | 1,956.25 | 7,825.01 | 78,250.12 |
| Provisión riesgo: .2% × 5,000 GMV × N | 250.00 | 1,000.00 | 10,000.00 |

## No confundir comisiones con pérdidas

- Stripe disputa recibida: MXN 150 según tarifa recibida; Smart Disputes 30% del monto recuperado cuando gana y se utiliza el servicio. Cotizar tratamiento fiscal, disponibilidad y reglas. No se presuponen como gasto mensual si no se asigna volumen.
- Comisión original suele no devolverse al reembolsar. Probar sensibilidad con reembolsos y rechazos de cobro; no contarlos como ingreso neto permanente.
- Internacional +0.5% y conversión +2% cuando apliquen. No se añaden al baseline nacional en MXN; calcular solo las operaciones elegibles.
- Transferencia bancaria Stripe MXN 7 + IVA/transacción y OXXO 4% + MXN 3 son métodos alternativos de cobro propio. No son tarifas SPEI de Finco ni se suman a la misma transacción con tarjeta.

## Reservas

La bolsa de **MXN 10/usuario/mes** asume .2% del GMV de MXN 5,000. No es tasa histórica ni garantía de suficiencia. Cubre una provisión genérica de riesgo, no necesariamente cada disputa o fee. Si se modelan pérdidas esperadas y contracargos por separado, explicar qué queda dentro para no duplicarlos.

Reserva/garantía impuesta por emisor, prefondo y retenciones contractuales: Q y capital de trabajo separado. Los depósitos de usuarios no son gastos operativos ni ingresos propios. Fondos de clientes siempre segregados según estructura legal.

# 33 / WhatsApp y otros costos condicionados

No incluido en el baseline: habilitación comercial del asistente pendiente. No se enviaron mensajes.

Los términos recibidos restringen proveedores de asistentes generalistas de IA con excepciones EEE/Brasil. México no figura en esas excepciones. Cloud API, un BSP o un adaptador de Hermes no conceden elegibilidad. Presupuestar solo soporte/avisos u otro caso confirmado como admisible. [S25]

| Canal | Tarifa del antecedente | Condiciones / Q |
|---|---|---|
| Plivo BSP | USD .001 por mensaje entrante/saliente + USD 10/WABA/mes. Meta: marketing .0397; utility/auth .0085. | Tabla BSP menciona 1,000 service free y luego cargo; confirmar rate card por WABA. [C20] |
| Twilio BSP | USD .005 por mensaje entrante/saliente + Meta; failed .001 según condición. | No asumir que .005 incluye Meta ni que cada fallo cobra igual. [C21] |
| Meta directo | Texto oficial recibido: service y utility de respuesta gratuitos. | Conflicto con tablas BSP recientes sobre service; revalidar ventanas, país, categorías y recargos. [C22] |

## Ejemplo elegible de avisos; no tarifa generalista

100 mensajes por usuario/mes: 60 entrantes + 40 plantillas utility salientes, todas facturables fuera de ventana. Referencia Meta .0085 por plantilla; sin marketing ni service saliente. Cantidades E, no tráfico medido.

| USD antes de impuestos | 25 | 100 | 1,000 |
|---|---|---|---|
| Plivo: 10 + N×(100×.001 + 40×.0085) | 21.00 | 54.00 | 450.00 |
| Twilio: N×(100×.005 + 40×.0085) | 21.00 | 84.00 | 840.00 |

Esta ilustración evita fijar un precio del service en conflicto; no prueba la elegibilidad ni una oferta contractual. Confirmar rate card, ventanas, país del receptor, categorías, impuestos, mínimos y renta. No sumar Plivo y Twilio: son alternativas.

## Extras que se activan por decisión

Apple Developer USD 99/año; Google Play USD 25 una vez. Comisiones de compras digitales/IAP y reglas por tienda: Q, no asumir Stripe en app. Voz GPT Live1 de referencia USD .05/min más backend/modelos/herramientas; no es precio todo incluido. Gmail con datos restringidos puede requerir evaluación de seguridad: provisión inicial de sección 23, costos anuales Q. [C23–C24, M10]

# 34 / Total mensual por escenario

Baseline con KYC externo, OTP y membresía cobrada. Finco, marketing y extras Q se añaden; no valen cero.

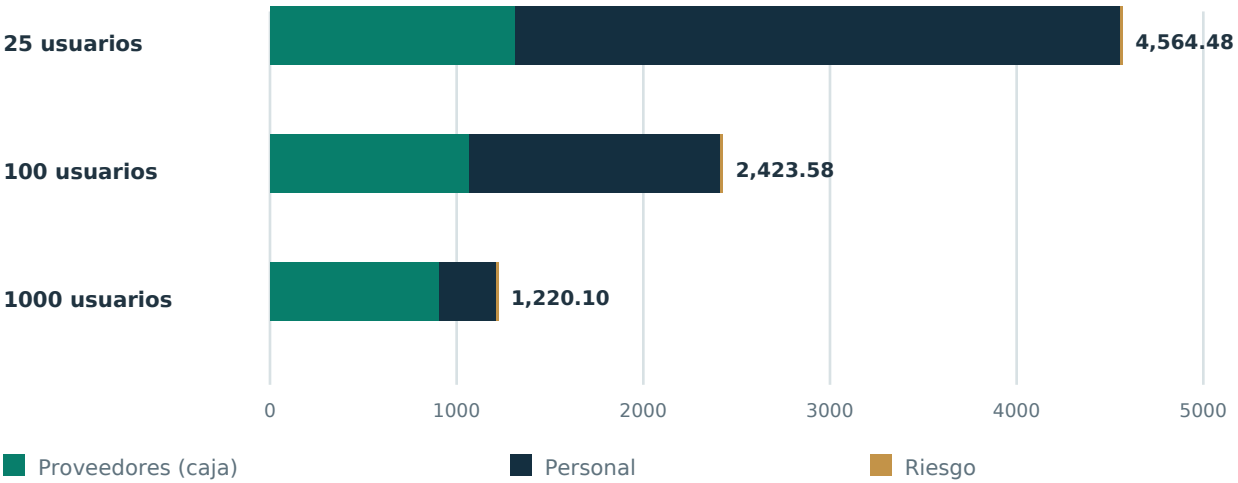
| Partida / mes | 25 | 100 | 1,000 |
|---|---|---|---|
| Central USD | 350.165 | 723.665 | 1,600.265 |
| VMs + backups USD | 780.00 | 3,120.00 | 31,200.00 |
| Secretos USD | 38.01425 | 128.04800 | 1,208.45300 |
| IA USD | 14.52 | 58.08 | 580.80 |
| Búsquedas USD | 7.50 | 30.00 | 300.00 |
| CFDI bruto MXN | 314.00 | 359.00 | 899.00 |
| **Tecnología: caja MXN** | 27,926.62 | 94,546.20 | 810,335.82 |
| KYC + OTP USD | 128.4140 | 171.8560 | 841.0600 |
| Stripe neto MXN | 1,686.43 | 6,745.70 | 67,457.00 |
| Proveedores netos MXN (incl. tecnología) | 28,329.38 | 91,688.16 | 782,843.56 |
| Provisión IVA sobre proveedores MXN | 4,532.70 | 14,670.11 | 125,254.97 |
| **Proveedores: caja MXN** | 32,862.08 | 106,358.27 | 908,098.53 |
| Operación humana MXN | 81,000.00 | 135,000.00 | 302,000.00 |
| Riesgo: provisión MXN | 250.00 | 1,000.00 | 10,000.00 |
| **Total caja modelada MXN** | **114,112.08** | **242,358.27** | **1,220,098.53** |
| Equivalente total USD a 20 | 5,705.60 | 12,117.91 | 61,004.93 |
| Caja por usuario MXN | 4,564.48 | 2,423.58 | 1,220.10 |

Las primeras filas son componentes: no sumar subtotales entre sí. **Tecnología caja = (central + VM + secretos + IA + búsqueda) × 20 × 1.16 + CFDI bruto.** Proveedores caja agrega (KYC+OTP)×20×1.16 y Stripe neto×1.16. Total agrega personal y riesgo, sin otro IVA sobre esos dos conceptos.

Provisión de caja por IVA no equivale a gasto definitivo: su acreditamiento, importación, retenciones y compensación con IVA cobrado deben determinarse. Los totales no son cotización integral de lanzamiento porque Finco sigue pendiente.

# 35 / Economía, personal y sensibilidad

El ahorro por escala proviene de repartir personal y central; la VM por usuario no desaparece.




Caja mensual por usuario en MXN. A 1,000 usuarios, personal se diluye, pero la flota DO conserva USD 31.20 por persona antes de impuestos. No es curva de demanda ni costo observado.

| Operación humana (E) MXN/mes | 25 | 100 | 1,000 |
|---|---|---|---|
| Mantenimiento de software | 40,000.00 | 80,000.00 | 160,000.00 |
| DevOps / guardias | 20,000.00 | 20,000.00 | 40,000.00 |
| Atención y conciliación | 7,500.00 | 15,000.00 | 60,000.00 |
| Contabilidad mensual | 3,500.00 | 5,000.00 | 12,000.00 |
| Asesoría legal / cumplimiento | 10,000.00 | 15,000.00 | 30,000.00 |
| **Total operación** | 81,000.00 | 135,000.00 | 302,000.00 |

Mantenimiento/guardias son fracciones de capacidad, no promesa de soporte ilimitado 24/7. Altas, disputas y conciliación pueden requerir más personal. El caso 1,000 prevé MXN 60,000 de atención, no un call center dimensionado por datos.

| A MXN 1,499 IVA incluido | 25 | 100 | 1,000 |
|---|---|---|---|
| Ingresos netos mensuales MXN | 32,306.03 | 129,224.14 | 1,292,241.38 |
| Resultado normalizado antes de Q / ISR | -77,273.35 | -98,464.02 | 197,397.82 |
| Precio bruto de equilibrio por usuario | 5,272.72 | 2,701.15 | 1,258.00 |

El resultado usa ingresos sin IVA y proveedores netos para no mezclar impuestos acreditables con margen. Supone 100% de usuarios pagando, sin churn, descuentos ni incobrables. Precio de equilibrio recalcula la comisión variable de Stripe al nuevo precio; no fija la comisión de MXN 1,499 para todos los precios. No incluye amortización de inversión, Finco, marketing, IAP ni ISR.

# 36 / Sensibilidad y caja para crecer

| FX MXN/USD | 25: caja MXN | 100: caja MXN | 1,000: caja MXN |
|---|---|---|---|
| 18.6678 | 112,074.36 | 235,818.88 | 1,164,882.21 |
| 20 | 114,112.08 | 242,358.27 | 1,220,098.53 |
| 22 | 117,171.26 | 252,175.69 | 1,302,993.47 |

Solo cambian partidas denominadas en USD; nómina, Facturapi, comisión de Stripe en MXN y bolsa de riesgo no se convierten de nuevo. 18.6678 es el FIX histórico indicado, 20 y 22 son escenarios, no pronósticos.

| Tareas por usuario / mes | 25: caja MXN | 100: caja MXN | 1,000: caja MXN |
|---|---|---|---|
| 20 | 114,112.08 | 242,358.27 | 1,220,098.53 |
| 100 | 116,155.54 | 250,532.09 | 1,301,836.77 |
| 200 | 118,709.86 | 260,749.37 | 1,404,009.57 |

En esta sensibilidad solo IA y búsquedas escalan con tareas; no demuestra que VMs, soporte, red o capacidad central resistan 5× o 10× carga. Si crecen, el costo será mayor. Para 1,000 usuarios, 100 tareas/mes añade MXN 81,738.24 frente a baseline.

## Siguientes dos meses, después del desarrollo

Sin ampliar equipo de desarrollo, dos meses de operación presupuestada agregan **MXN 228,224.16** a 25 usuarios o **MXN 484,716.54** a 100. Base de cuatro meses + esos dos meses: MXN 2,834,271.95 / 3,090,764.33, todavía más piloto adicional, Finco y extras. No sumar otra vez cuatro meses de operación a cuatro meses de nómina del mismo equipo.

## Estrés que todavía requiere datos

- Duplicar recursos de VM a 8 GB suma USD 31.20 por usuario/mes netos: a 1,000, MXN 723,840 de caja con FX 20 y provisión IVA.
- Fly 60 h puede bajar cómputo, pero requiere medir uptime real, discos, egress, arranque, aislamiento y cobertura de copias. El caso 24/7 es cercano al costo DO.
- Añadir tasa real de reintentos, modelos más capaces, contexto creciente, temporadas, soporte y pérdidas. No aplicar un multiplicador oculto a cifras que ya tienen contingencia.

# 37 / Cotización Finco y partidas abiertas

Q = pendiente; no se inventan tarifas ni se presentan como cero. No se contactó a proveedores.

| Bloque a cotizar | Unidad / fórmula para integrar al modelo |
|---|---|
| Alta / programa / integración | Cargo único de setup + certificación + implementación no cubierta. Indicar IVA, moneda y plazo. |
| Mínimo mensual | max(mínimo, cargos consumidos elegibles), no mínimo + consumo si el contrato los compensa. |
| CLABE / cuenta | Altas × costo apertura + cuentas vivas × mantenimiento + cierres/devoluciones. |
| SPEI | Entradas × tasa + salidas × tasa + devoluciones × tasa + excepciones; límites y conciliación. |
| Tarjeta digital | Emisiones × tarifa + tarjetas activas × mes + reposiciones/bloqueos/tokenización. |
| Procesamiento tarjeta | Autorizaciones, declinaciones, capturas, 3DS, internacionales y FX según unidad real. |
| Devoluciones / disputas | Refunds, reversas, chargebacks y recuperación, más responsabilidad por pérdidas no duplicada. |
| KYC / AML | Si va incluido, retirar Veriff por ese alta; diferenciar revisión manual, re-KYC y monitoreo. |
| Reservas / garantías | Capital inmovilizado, % y base, calendario de liberación; no gasto ni fondo de usuarios. |
| Operación / SLA / salida | Conciliación, soporte, incidentes, reportes, escalamiento, exportación y migración. |

**Modelo final = total mostrado + Q operativo + marketing + extras elegidos + fiscalidad efectiva − partidas sustituidas.** Capital requerido añade reservas contractuales y prefondo propios, sin mezclar dinero ajeno. Primero confirmar identidad/contrato de Finco; no usar Monato como sustituto documental.

## Otras Q materiales

Evaluación/renovación OAuth; PCI y alcance de auditoría; seguros cyber/E&O; guardia de seguridad, respuesta a incidentes y recuperación multirregión; campañas/CAC, comisiones de tienda; asesoría especializada extra; soporte de KYC/contracargos; cobertura nocturna; FX y mínimos empresariales. Bolsas de pentest/legal ya modeladas no se repiten por el mismo entregable.

# 38 / Recomendación y comprobaciones finales

## Decisión provisional de producto y modelo

- Mantener Hermes en VM CPU exclusiva por persona. Inferencia mediante broker/API común con identidad, cuotas, logs redactados y contratos de privacidad; sin compartir memoria o sesiones personales.
- Probar GPT-OSS-120B Groq como ruta de texto de producción candidata. Evaluar GPT-OSS-20B para tareas sencillas, Qwen3.6 visual y Cerebras120B para máxima velocidad antes de cotizar Enterprise.
- DigitalOcean es baseline claro, sin ahorro por apagado. Evaluar Fly solo después de medir horas activas y restauración. No contratar GPU al inicio: primero calidad, latencia y consumo reales.
- Cotizar Finco y validar el flujo legal antes de comprometer precio final o dinero real. PWA y pago directo al comercio permiten aprender mientras se documenta.

## Qué fue verificado en esta entrega

Se recalculó el presupuesto con Decimal y se contrastaron escenarios/inversión mediante un cálculo independiente con fracciones exactas. Se revisaron unidades, impuestos, mínimos, separaciones y exclusiones; PDF renderizado para inspección visual y extracción de texto. No son pruebas de una aplicación.

En la sesión cloud se pudieron leer README/licencia oficiales de Hermes y README GPT-OSS vía GitHub. Confirman MIT, Apache 2.0, herramientas y requisitos Harmony/80 GB. Los portales de Groq, Cerebras y DigitalOcean devolvieron denegación de red, así que sus precios y los demás antecedentes se identifican como investigación previa facilitada, no reconsulta exitosa aquí. No se cambiaron reglas de red para aparentar verificación.

## Qué no fue hecho

Sin benchmarks, llamadas pagadas de inferencia, despliegues, compras de infraestructura, contacto con proveedores, integración Finco ni pruebas de pagos reales. No se confirmó disponibilidad privada, tarifa Enterprise, residencia de datos o SLA. No hay repositorio de aplicación que validar: la entrega es este documento.

## Antes de invertir

Validar tarifas y región en cuentas oficiales; obtener contratos, rate cards e identidad legal; medir 100 tareas y concurrencia; probar VM por usuario y restauración; aprobar controles de dinero y postventa. Solo entonces convertir los escenarios en presupuesto aprobado.

**Inversión base: MXN 2,606,047.79. Operación mensual modelada: MXN 114,112.08 / 242,358.27 / 1,220,098.53 para 25 / 100 / 1,000 usuarios. Finco y extras Q permanecen fuera: no son cero.**

# 39 / Fuentes: Producto, arquitectura y regulación

Referencias 1–8 de 32 del grupo | Antecedente fechado 11/11/2026

“Antecedente” o “P recibido” significa investigación facilitada desde el trabajo previo. No equivale a abrir el portal otra vez en esta sesión. “Reconsultado” identifica lectura exitosa actual. Las tarifas se usan para planeación y necesitan confirmación antes de contratar.

**[S01] Meta: Muse en México**
https://about.fb.com/ltam/news/2026/09/presentamos-muse-el-primer-agente-de-ia-personal-del-mundo-creado-para-todos/
Antecedente: actualización 05/11/2026 sobre disponibilidad; no prueba acceso de integración propia.

**[S02] Hermes Agent: documentación**
https://hermes-agent.nousresearch.com/docs
Antecedente de funciones, no pruebas propias. README oficial reconsultado en GitHub en esta sesión.

**[S03] Hermes Agent: licencia MIT**
https://github.com/NousResearch/hermes-agent/blob/main/LICENSE
Reconsultada vía raw.githubusercontent.com: MIT y conservación de avisos. No cubre modelos ni servicios externos.

**[S04] Hermes: perfiles**
https://hermes-agent.nousresearch.com/docs/user-guide/profiles
Antecedente: separación de estado, home e herencia de claves/logins; probar versión fijada.

**[S05] Hermes: seguridad**
https://hermes-agent.nousresearch.com/docs/user-guide/security
Antecedente: aprobaciones/aislamiento; no certifica la arquitectura propia.

**[S06] Hermes: API Server**
https://hermes-agent.nousresearch.com/docs/user-guide/features/api-server
Antecedente: HTTP, eventos/aprobaciones, autenticación, límites y perfiles; revisión previa indicó contraste con Context7.

**[S07] Hermes: WhatsApp vía Baileys**
https://hermes-agent.nousresearch.com/docs/user-guide/messaging/whatsapp
Antecedente: puente no oficial, emulación Web y advertencia de bloqueo.

**[S08] Hermes: WhatsApp Cloud API**
https://hermes-agent.nousresearch.com/docs/user-guide/messaging/whatsapp-cloud
Antecedente: adaptador oficial y limitación de plantillas. Revisar versión al implementar.

# 40 / Fuentes: Producto, arquitectura y regulación

Referencias 9–16 de 32 del grupo | Antecedente fechado 11/11/2026

“Antecedente” o “P recibido” significa investigación facilitada desde el trabajo previo. No equivale a abrir el portal otra vez en esta sesión. “Reconsultado” identifica lectura exitosa actual. Las tarifas se usan para planeación y necesitan confirmación antes de contratar.

**[S09] LangChain: stack de agentes**
https://www.langchain.com/oss-overview
Antecedente: alternativas LangGraph/Deep Agents y persistencia.

**[S10] Link: pagos para agentes**
https://docs.link.com/
Antecedente: cuentas US/Canadá, aprobación y credenciales acotadas. No se confirmó habilitación México.

**[S11] Stripe México: actividades restringidas**
https://stripe.com/mx/legal/restricted-businesses
Antecedente: valor almacenado y facilitación; requerir validación expresa del caso.

**[S12] Stripe México: precios**
https://stripe.com/mx/pricing
Antecedente: nacional 3.6%+MXN3, internacional/FX/disputas; impuestos y contrato por validar.

**[S13] Stripe: transferencias bancarias**
https://docs.stripe.com/payments/bank-transfers
Antecedente: países/monedas y saldo de cobro; no wallet general.

**[S14] Stripe Connect**
https://docs.stripe.com/connect
Antecedente: plataformas y cuentas conectadas, según país y elegibilidad.

**[S15] Stripe Issuing: disponibilidad**
https://docs.stripe.com/issuing/global
Antecedente: programas geográficos; no inferir emisión mexicana.

**[S16] Stripe: webhooks**
https://docs.stripe.com/webhooks
Antecedente: repeticiones, desorden, firmas y reintentos.

# 41 / Fuentes: Producto, arquitectura y regulación

Referencias 17–24 de 32 del grupo | Antecedente fechado 11/11/2026

“Antecedente” o “P recibido” significa investigación facilitada desde el trabajo previo. No equivale a abrir el portal otra vez en esta sesión. “Reconsultado” identifica lectura exitosa actual. Las tarifas se usan para planeación y necesitan confirmación antes de contratar.

**[S17] Stripe: idempotencia**
https://docs.stripe.com/api/idempotent_requests
Antecedente: claves y comportamiento según versión de API.

**[S18] Cámara de Diputados: Ley Fintech**
https://www.diputados.gob.mx/LeyesBiblio/pdf/LRITF.pdf
Antecedente: artículos 22, 47 y 58; aplicabilidad al flujo concreto, no dictamen individualizado.

**[S19] Orden Jurídico Nacional: datos personales**
https://www.ordenjuridico.gob.mx/Documentos/Federal/html/wo125102.html
Antecedente: ley de 20/03/2025, consentimiento, seguridad y ARCO; corroborar reformas.

**[S20] Cámara de Diputados: LFPC**
https://www.diputados.gob.mx/LeyesBiblio/pdf/LFPC.pdf
Antecedente: texto con reforma 12/12/2025, artículo 76 Bis, recurrencia/cancelación.

**[S21] SAT: requisitos de factura**
https://www.sat.gob.mx/minisitio/Factura/solicita_requisitos.htm
Antecedente: datos fiscales y comprobante; validar con PAC/contador.

**[S22] PCI SSC: CVV**
https://www.pcisecuritystandards.org/faqs/1319/
Antecedente: no conservar CVV tras autorización en flujo comercial; alcance por determinar.

**[S23] Google: scopes Gmail**
https://developers.google.com/workspace/gmail/api/auth/scopes
Antecedente: scopes, verificación y evaluación para datos restringidos.

**[S24] Apple: App Review Guidelines**
https://developer.apple.com/app-store/review/guidelines/
Antecedente: bienes físicos vs compras digitales; revisar storefront/modalidad vigentes.

# 42 / Fuentes: Producto, arquitectura y regulación

Referencias 25–32 de 32 del grupo | Antecedente fechado 11/11/2026

“Antecedente” o “P recibido” significa investigación facilitada desde el trabajo previo. No equivale a abrir el portal otra vez en esta sesión. “Reconsultado” identifica lectura exitosa actual. Las tarifas se usan para planeación y necesitan confirmación antes de contratar.

**[S25] WhatsApp: Business Solution Terms**
https://www.whatsapp.com/legal/business-solution-terms/
Antecedente del texto oficial indexado: AI Providers y excepciones EEE/Brasil. Apertura previa redirigió a login; revalidación del caso pendiente.

**[S26] CNBV: PES**
https://www.cnbv.gob.mx/Paginas/InfoPES.aspx
Antecedente de registro para verificar entidad/sector. Finco no verificado por falta de identidad.

**[S27] CONDUSEF: consulta de institución**
https://www.gob.mx/condusef/es/articulos/vas-a-contratar-un-servicio-financiero?idiom=es
Antecedente de SIPRES. Registro no acredita cada producto.

**[S28] Monato Fincore: referencia no atribuida a Finco**
https://docs.monato.com/fincore/overview/
Hallazgo previo; identidad no confirmada. No se usa para prometer cuentas o tarjetas de Finco.

**[S29] Agentic Commerce Protocol**
https://www.agenticcommerce.dev/
Antecedente: estándar para participantes compatibles, no acceso universal.

**[S30] OpenAI: uso de computadora**
https://developers.openai.com/api/docs/guides/tools-computer-use
Antecedente: aislamiento, contenido no confiable, confirmaciones y verificación.

**[S31] AWS: instancias detenidas**
https://aws.amazon.com/ec2/faqs/
Antecedente: detención no elimina cargos de disco/recursos; ejemplo, no proveedor seleccionado.

**[S32] AWS: hibernación EC2**
https://docs.aws.amazon.com/AWSEC2/latest/UserGuide/instance-hibernate-overview.html
Antecedente: guardar RAM tiene requisitos; persistencia de archivos no exige hibernar.

# 43 / Fuentes: Precios y servicios

Referencias 1–8 de 30 del grupo | Antecedente fechado 11/11/2026

“Antecedente” o “P recibido” significa investigación facilitada desde el trabajo previo. No equivale a abrir el portal otra vez en esta sesión. “Reconsultado” identifica lectura exitosa actual. Las tarifas se usan para planeación y necesitan confirmación antes de contratar.

**[C01] DigitalOcean: Droplets**
https://www.digitalocean.com/pricing/droplets
P recibido: 2vCPU/4GiB/80GiB USD24; 4vCPU/8GiB/160GiB USD48; 1vCPU/2GiB USD12. Reconsulta cloud: 403.

**[C02] DigitalOcean: backups**
https://www.digitalocean.com/pricing/backups
P recibido: semanal20%, diario30%; diario con siete días de retención.

**[C03] DO PostgreSQL: tarifas y nuevas cuentas**
https://docs.digitalocean.com/products/databases/postgresql/details/pricing/
P recibido: Standard2GB30.45, extra .215/GiB; cuentas nuevas desde15/10/2026 sin standby Standard; Advanced desde130/nodo, extra .115/GiB.

**[C04] DO: managed databases y Valkey**
https://www.digitalocean.com/pricing/managed-databases
P recibido: Valkey1GB15 y2GB30; se contrasta con documentación específica PostgreSQL.

**[C05] DO: balanceadores**
https://www.digitalocean.com/pricing/load-balancers
P recibido: regional desde USD12/nodo/mes.

**[C06] DO Spaces**
https://www.digitalocean.com/pricing/spaces-object-storage
P recibido: USD5, 250GiB y1TiB egreso; extra .02/GiBstorage, .01/GiBegreso.

**[C07] Cloudflare: planes**
https://www.cloudflare.com/plans/
P recibido: Pro25 y Business250 mensuales; anual equivalente20 y200.

**[C08] Sentry: precios**
https://sentry.io/pricing/
P recibido: Team29/26 y Business89/80 mensual/anual; extras según consumo.

# 44 / Fuentes: Precios y servicios

Referencias 9–16 de 30 del grupo | Antecedente fechado 11/11/2026

“Antecedente” o “P recibido” significa investigación facilitada desde el trabajo previo. No equivale a abrir el portal otra vez en esta sesión. “Reconsultado” identifica lectura exitosa actual. Las tarifas se usan para planeación y necesitan confirmación antes de contratar.

**[C09] Resend: precios**
https://resend.com/pricing/
P recibido: Pro20/50k emails, extra .90/1,000; free3k con100/día.

**[C10] GitHub: Team**
https://github.com/pricing
P recibido: USD4/seat/mes. No se auditó cuota CI incluida del contrato.

**[C11] Google Workspace: flexible/anual**
https://knowledge.workspace.google.com/admin/billing/compare-flexible-and-annual-fixed-term-payment-plans
P recibido: Starter8.40 flexible o7 anual por usuario/mes.

**[C12] Namecheap: .com**
https://www.namecheap.com/domains/registration/gtld/com/
P recibido: promo12.08, regular15.98, renovación19.98/año. Sin disponibilidad ni tarifa .mx verificadas.

**[C13] AWS Secrets Manager**
https://aws.amazon.com/secrets-manager/pricing/
P recibido: .40/secreto/mes +.05/10k consultas; cantidades del modelo son E.

**[C14] Brave Search API**
https://brave.com/search/api/
P recibido: USD5/1k búsquedas; créditoUSD5 omitido conservadoramente.

**[C15] Facturapi: precios**
https://www.facturapi.io/pricing
P recibido: MXN299/mes +.60/CFDI, IVA incluido.

**[C16] Veriff: precios**
https://www.veriff.com/pricing
P recibido: Essential .80 mínimo49; Plus1.39 mínimo99; Premium1.89 mínimo209. AML .64. Monitoring .09 con unidad pendiente.

# 45 / Fuentes: Precios y servicios

Referencias 17–24 de 30 del grupo | Antecedente fechado 11/11/2026

“Antecedente” o “P recibido” significa investigación facilitada desde el trabajo previo. No equivale a abrir el portal otra vez en esta sesión. “Reconsultado” identifica lectura exitosa actual. Las tarifas se usan para planeación y necesitan confirmación antes de contratar.

**[C17] Twilio: SMS México**
https://www.twilio.com/en-us/sms/pricing/mx
P recibido (octubre2026): long-code out .1819/segmento, in .02. Recargos/número Q.

**[C18] Twilio Verify**
https://www.twilio.com/en-us/verify/pricing
P recibido: .05/verificación exitosa más canal; intentos definidos como E.

**[C19] Stripe Billing**
https://stripe.com/mx/billing/pricing
P recibido: .7% volumen adicional a Payments; baseline propio con suscripción web.

**[C20] Plivo: WhatsApp México**
https://www.plivo.com/whatsapp/pricing/mx/
P recibido: marketing .0397, utility/auth/service .0085, BSP .001/message, WABA10/mes, referencia a1,000 service free. Conflicto con Meta pendiente.

**[C21] Twilio: WhatsApp**
https://www.twilio.com/en-us/whatsapp/pricing
P recibido: .005/mensaje más Meta; fee de fallo .001 bajo condiciones.

**[C22] WhatsApp Business: platform pricing**
https://whatsappbusiness.com/products/platform-pricing/
Antecedente oficial: service y utility de respuesta gratuitas; discrepa con parte de tablas BSP. Rate card del WABA pendiente.

**[C23] Apple Developer Program**
https://developer.apple.com/help/account/membership/program-enrollment/
P recibido: USD99/año; comisiones IAP y reglas requieren análisis específico.

**[C24] Google Play Console**
https://support.google.com/googleplay/android-developer/answer/6112435?hl=en
P recibido: USD25 una vez; no incluye comisiones de tienda.

# 46 / Fuentes: Precios y servicios

Referencias 25–30 de 30 del grupo | Antecedente fechado 11/11/2026

“Antecedente” o “P recibido” significa investigación facilitada desde el trabajo previo. No equivale a abrir el portal otra vez en esta sesión. “Reconsultado” identifica lectura exitosa actual. Las tarifas se usan para planeación y necesitan confirmación antes de contratar.

**[C25] Banco de México: tipo de cambio**
https://www.banxico.org.mx/tipcamb/tipCamMIAction.do?idioma=sp
Antecedente: 11/11/2026 N/E; último FIX determinado10/11:18.6678. Modelo20 es colchón, no cotización actual.

**[C26] Hays: guía salarial LATAM**
https://salaryguide-americas.hays.com/latam/es/
Referencia previa consultada, sin tabla pública verificable por cada rol. No respalda como dato observado los montos E.

**[C27] CodersLink: reporte TI México**
https://coderslink.com/talento/reporte-salarios-ti-mexico/
Referencia previa, sin tabla verificable por cada rol. Personal es planeación, no encuesta salarial reproducida.

**[C28] DO: facturación de Droplets**
https://docs.digitalocean.com/products/droplets/details/pricing/
Antecedente: cómputo facturado aunque esté apagada mientras exista; por segundo con cap mensual.

**[C29] Fly: precios actuales**
https://docs.fly.io/about/pricing
Antecedente: destino actual tras redirección; IAD/EWR2x2GB13.39, RAM6/GB; rootfs detenido .15, volumen .15, snapshot .08/GBmes, egressNA .02/GB. Precios viejos indexados no usados.

**[C30] Stripe México: otros métodos**
https://stripe.com/mx/pricing/local-payment-methods
P recibido: transferencia7MXN+IVA, OXXO4%+3; alternativas propias, no tarifas Finco.

# 47 / Fuentes: Modelos, velocidad e inferencia

Referencias 1–8 de 11 del grupo | Antecedente fechado 11/11/2026

“Antecedente” o “P recibido” significa investigación facilitada desde el trabajo previo. No equivale a abrir el portal otra vez en esta sesión. “Reconsultado” identifica lectura exitosa actual. Las tarifas se usan para planeación y necesitan confirmación antes de contratar.

**[M01] Qwen3.6-35B-A3B: model card**
https://huggingface.co/Qwen/Qwen3.6-35B-A3B
Antecedente: Apache2.0,35B/3B activos, visión/tools,vLLM/SGLang. No se midió español/seguridad.

**[M02] DeepInfra: Qwen3.6-35B-A3B**
https://deepinfra.com/Qwen/Qwen3.6-35B-A3B
P recibido: FP8,JSON/Function/Multimodal,262144ctx,.10/.95 por1M,cache.10,Priority1.5x,Flex.8x. Sin TPS garantizados.

**[M03] Groq: catálogo de modelos**
https://console.groq.com/docs/models
P recibido: OSS120B500TPS .15/.60; OSS20B1000TPS .075/.30; producción131072ctx,Developer250kTPM/1000RPM. Qwen3.8preview450TPS .80/4. Reconsulta cloud:403.

**[M04] Cerebras: precios**
https://www.cerebras.ai/pricing
Antecedente de tabla oficial indexada: OSS120B~3000TPS .35/.75; Qwen3.8~1850 .99/1.49. Developer evaluación/desarrollo; Enterprise producción Q. Reconsulta cloud:403.

**[M05] Cerebras: rate limits**
https://inference-docs.cerebras.ai/support/rate-limits.md
Antecedente: reserva estimada incluye max_completion_tokens; TPM/RPM no es TPS.

**[M06] OpenAI GPT-OSS-120B: model card**
https://huggingface.co/openai/gpt-oss-120b
Antecedente: Apache2,117B/5.1B activos,MXFP4/Harmony,texto,80GB; README oficial corroborado vía GitHub [M11].

**[M07] Groq: compatibilidad OpenAI**
https://console.groq.com/docs/openai
Antecedente: compatibilidad mayoritaria; Hermes parser/tools/reasoning por probar.

**[M08] Runpod: precios**
https://www.runpod.io/pricing
Antecedente actualizado09/11: SecureL40S1.09/h,A40/A6000.59,A100PCIe1.79,H100PCIe2.89,SXM3.99; networkstorage.07/GBmes. No Community.

# 48 / Fuentes: Modelos, velocidad e inferencia

Referencias 9–11 de 11 del grupo | Antecedente fechado 11/11/2026

“Antecedente” o “P recibido” significa investigación facilitada desde el trabajo previo. No equivale a abrir el portal otra vez en esta sesión. “Reconsultado” identifica lectura exitosa actual. Las tarifas se usan para planeación y necesitan confirmación antes de contratar.

**[M09] Modal: precios**
https://modal.com/pricing
Alternativa serverless del antecedente. Sin tarifa fijada aquí: Q; no se usa para totales.

**[M10] OpenAI: API pricing**
https://developers.openai.com/api/docs/pricing
P recibido: Sol2/10,Luna.10/.50,Astra10/50 por1M; WebSearch10/1k+tokens; GPTLive1.05/min más backend/model/tools. Referencias cerradas, no equivalencia de calidad.

**[M11] OpenAI: GPT-OSS README oficial**
https://github.com/openai/gpt-oss/blob/main/README.md
Reconsultado en esta sesión vía raw.githubusercontent.com: Apache2,Harmony obligatorio,MXFP4,120B80GB/20B16GB y tools de referencia no aptas por sí solas para producción.