01 / Roadmap de desarrollo y validación

Agente personal para México | Plan ejecutable v1.0 | 11 de noviembre de 2026

Primero construiremos una experiencia navegable con datos simulados: pedir → ver progreso → comparar → aprobar o rechazar → ver el resultado. En la primera quincena probaremos también Hermes en dos VMs exclusivas, antes de ampliar la implementación.

Resultado del primer hito: podrás abrir la web desde celular y computadora, recorrer una compra simulada y revisar cada pantalla. Debe quedar claro qué hará el agente, cuánto cuesta, qué permiso pide y qué ocurrió. Todavía sin fondos ni compras reales.

Tres validaciones en cada entrega

- **Visual:** diseño consistente, texto legible, sin recortes, móvil usable y estados de carga, vacío, error y recuperación.
- **Funcional:** controles conectados a estados reales; permisos y aprobaciones validados en servidor; cerrar la app no pierde tareas.
- **De confianza:** no inventar éxito, precio, saldo ni compra. Una operación incierta aparece pendiente de verificar; nunca como terminada.

Alcance que conservamos

PWA/web primero. Una VM CPU exclusiva y persistente por usuario con Hermes, navegador, archivos, cookies y memoria propios. Agenda y colas centrales despiertan VMs detenidas; la VM sigue trabajando con la app cerrada. Identidad, permisos financieros, consentimientos y ledger permanecen fuera de la VM.

Groq GPT-OSS-120B es candidato de texto, Qwen visual y Cerebras de evaluación; se seleccionarán por pruebas, no por TPS publicados solamente. Finco necesita identidad, contrato y sandbox. WhatsApp y apps nativas se incorporan después de validar elegibilidad y políticas.

Cómo usaremos este plan

24 semanas de referencia con equipo disponible; los tiempos de terceros no están garantizados. Cada fase termina con una demo y evidencia. Una dependencia externa puede retrasar su entrega sin impedir el trabajo independiente. Este documento amplía el roadmap técnico; no sustituye el presupuesto y fuentes del PDF v1.2.

Estado actual: planificación. Las pruebas aquí descritas están pendientes de implementación/ejecución. En este encargo se creó y revisó el documento; no se desarrolló ni desplegó la aplicación.

02 / Todas las etapas y su orden

Las semanas son relativas al arranque. F00 y F01 comparten la semana 1; F02 cierra la quincena inicial.

Fase	Cuándo	Qué construimos	Condición para cerrar
F00	Días 1–2	Definir experiencia, alcance y diseño	Recorrido y componentes con estados aprobados.
F01	Días 3–5	Prototipo navegable y base del proyecto	Flujo completo simulado en móvil y escritorio.
F02	Semana 2	Hermes, modelos y dos VMs propias	Viabilidad técnica, aislamiento y tiempos medidos.
F03	Semanas 3–4	Identidad, tareas y gestor de VMs	Acceso aislado, segundo plano y recuperación.
F04	Semanas 5–6	Agente útil, comparación y memoria	Tareas del alcance con evidencia y datos propios.
F05	Semana 7	Cotizaciones, consentimiento y compra simulada	No ejecutar sin autorización válida.
F06	Semana 8*	Integraciones financieras en sandbox	Pago, pedido, reversa y devolución conciliados.
F07	Semanas 9–10	Validación integral y preparación operativa	Sin defectos críticos; salida controlada.
F08	Semanas 11–12*	Piloto por invitación, 25–50 personas	Tareas resueltas y postventa trazable.
F09	Semanas 13–16	Estabilización y escala 100–300	Costos, calidad y soporte medidos.
F10	Semanas 17–20*	Canales, conexiones y apps	Mismos permisos y estados en todos los canales.
F11	Semanas 21–24*	Más comercios, recurrencias y continuidad	Cada flujo nuevo conserva controles y margen.

* Finanzas, WhatsApp, OAuth, tiendas y comercios dependen de accesos/contratos. Si no están habilitados, mantener el flujo correspondiente pendiente. Un piloto de investigación o pago directo del usuario no valida la integración financiera pendiente.

03 / Primeros diez días de trabajo

Objetivo de quincena: experiencia visible y prueba técnica pequeña, sin construir toda la plataforma.

Día	Desarrollo / producto	Prueba y evidencia
1	Elegir usuario, tres tareas y un flujo de compra. Separar servicio, fondos y pago al comercio.	Recorrido dibujado; alcances, riesgos y criterios de aceptación escritos.
2	Diseño móvil: inicio, chat/tarea, comparación, aprobación y resultado. Componentes y colores.	Revisar lectura, navegación, precio total, acciones y estados con 5 personas del perfil.
3	Base PWA y componentes; datos de prueba deterministas; rutas navegables.	Arranca en entorno de desarrollo. Sin errores de consola ni datos reales expuestos.
4	Conectar flujo simulado: crear tarea, comparar y editar condiciones.	Pantallas en 360/390/1440 px; contenido largo, vacío y carga.
5	Aprobar/rechazar/cancelar simulado; pantallas de fallo y resultado incierto.	Demo completa; revisar con teclado y celular. Congelar primera referencia visual.
6	Fijar Hermes y proveedor de modelo candidato; preparar dos VMs exclusivas de prueba.	Revisar licencia/configuración y evitar herencia de secretos o sesiones.
7	Una tarea real de investigación sin pagos por VM; medir modelo y navegador.	A/B: memoria, archivos y cookies no se cruzan; registro de latencia y tokens.
8	Persistencia, parada, despertar por agenda externa y reconexión de interfaz.	Cerrar app, reiniciar VM y recuperar tarea sin repetir efectos.
9	Lote de evaluación y ataques de contenido; repetir regresión visual.	100 tareas propuestas para la prueba técnica; separar éxitos, fallos y bloqueos.
10	Decidir motor/modelo/perfil VM y ajustar alcance. Descomponer tickets siguientes.	Acta continuar/corregir/cambiar; evidencia visual y técnica, costos y riesgos abiertos.

El prototipo de días 3–5 debe mostrar que es una demostración. No presenta saldos inventados como dinero disponible ni afirma que exista una compra real. Los ejemplos y cuentas son sintéticos.

04 / F00: diseñar la experiencia mínima

Días 1–2 | Responsable: producto + UX | Backlog de referencia: P00, P01 y P20

Qué trabajaremos primero

Un caso de uso inicial: “encuentra este producto, compara opciones y déjame aprobar una compra con tope”. Elegir categoría y comercios candidatos sin prometer integraciones no confirmadas. Añadir investigación simple y seguimiento como las otras dos tareas del lote.

Entregable	Detalle revisable
Mapa del recorrido	Alta → conversación → tarea → opciones → aprobación → pedido/resultado → ayuda.
Navegación	Inicio, tareas, pedidos, conexiones/memoria y cuenta/soporte; nombres consistentes en móvil y escritorio.
Componentes	Botones, campos, tarjetas de opción, importes, fuentes, progreso, alertas, diálogos y estados de tarea.
Datos / contenido	Ejemplos mexicanos: MXN, domicilio parcial, variante, envío, fecha y zona horaria explícita.
Estados dibujados	Normal, vacío, cargando, sin conexión, error, permiso pendiente y resultado desconocido.
Límites de producto	Adultos; sin compra universal, transferencias libres, crédito ni autonomía financiera sin topes.

Cómo validaremos que se ve bien

- Caminar el prototipo en celular: ¿se entiende el siguiente paso sin explicar comandos? La acción primaria debe ser visible y el total inequívoco.
- No usar solo color para estados; acompañar con texto/icono. Diferenciar “solicitar aprobación” de “comprar” y “pago autorizado” de “pedido confirmado”.
- Revisar versiones con producto/UX/QA y registrar cambios por pantalla; no aceptar una captura bonita que omita errores o recuperación.

Cierre de fase

Un recorrido coherente, componentes y estados definidos, criterios por pantalla y alcance aprobado. Salida tangible: prototipo navegable de diseño; aún sin backend financiero.

05 / F01: prototipo web y base de desarrollo

Días 3–5 | Frontend + backend + QA | P05–P06 iniciales; P10–P11 y P19 simulados

Implementar la estructura visual y un recorrido con fixtures. Las respuestas y compras son simuladas y están etiquetadas. Esta entrega permite probar la interfaz antes de depender de Finco o comercios.

Trabajo	Resultado
Proyecto reproducible	README de arranque, herramientas fijadas, lockfile, variables de ejemplo sin secretos y scripts de validación.
PWA responsive	Inicio, chat, tareas, comparación, aprobación, pedidos y ajustes con navegación real.
Fixtures por estado	Escenarios repetibles de éxito, datos largos, sin resultados, error, precio cambiado y pago desconocido.
Contrato de API propuesto	Identidad, Task, Quote, Consent, Payment y Order tipados; separar mock de producción.
CI mínima	Build, revisión de tipos, pruebas de reglas implementadas y recorrido de interfaz simulado.
Entornos	Desarrollo/staging/producción separados por configuración; nunca conectar mocks al dinero real.

Pruebas obligatorias

- El usuario puede pedir, comparar, cambiar una variante, aprobar/rechazar y consultar resultado simulado sin rutas rotas.
- Clic repetido no duplica la acción visible. Botones deshabilitados tienen explicación y recuperación; un cargador no queda indefinido.
- Visual VIS-01 a VIS-12 en los estados aplicables; navegación por teclado y foco en diálogos. Capturas de cada pantalla crítica y sus errores.

Decisión técnica inicial propuesta

Frontend React + TypeScript; backend de control Python/FastAPI para integrar Hermes; PostgreSQL para estados y ledger, cola/agenda separada. Fijar versiones al iniciar F01. Esta propuesta no autoriza compartir runtime personal: Hermes y navegador siguen en una VM por usuario.

Salida: demo navegable, datos de prueba identificados y comandos reproducibles. No confundir este hito con autenticación segura, VM real o compra real: eso se valida después.

06 / F02: Hermes, modelos y VMs exclusivas

Semana 2 | Ingeniería IA + infraestructura + seguridad | P03–P04, P07 y P21 de viabilidad

Experimento	Qué debe demostrar
Motor fijado	Versión/commit, licencias y configuración reproducibles; adaptador privado, sin llave administrativa al cliente.
Dos usuarios / dos VMs	Hermes, disco, memoria, navegador, cookies y secretos propios; no basta un perfil o contenedor compartido.
Broker de inferencia	La plataforma aplica identidad, cuotas, proveedor/modelo y límite; no entrega llave global a la VM.
Tool-calling	El modelo genera argumentos válidos y Hermes interpreta herramientas/razonamiento sin acciones extra.
Persistencia	Detener y reanudar conserva archivos/memoria; las sesiones pueden requerir autenticación de nuevo.
Agenda central	Una VM detenida se despierta por eventos/horario externo, nunca por un cron dentro de esa misma VM.

Pruebas de la quincena

- VM-01 a VM-07 y SEC-01: usuario A no puede leer ni accionar en B mediante API, disco, navegador, respaldo o herramientas.
- Evaluación de 100 tareas del alcance con entradas conocidas, sin compras reales. Registrar éxito, errores, intervención, tokens y tiempo por tarea; no cambiar criterios para esconder fallos.
- Comparar candidato Groq120B, ruta sencilla Groq20B y ruta visual Qwen; Cerebras solo evaluación si existe acceso. Medir TTFT, primera herramienta y tiempo total con misma carga.
- PERF-01/02: probar concurrencia 1/5/20 donde el acceso permita, registrando cuota, red, errores y tokens. No presentar TPS publicitados como resultado propio.

Cierre

Motor, API y tamaño de VM elegidos por evidencia. Si Hermes requiere un fork profundo, rompe aislamiento o no recupera tareas, corregir o cambiar motor antes de escalar. No continuar con un fallo crítico conocido.

07 / F03: identidad, tareas y gestor de VMs

Semanas 3–4 | Backend + infraestructura + frontend + QA | P05–P07, P17 y P21

Construcción	Comportamiento esperado
Identidad y acceso	Sesión segura, recuperación, roles internos y tenant_id fijado en servidor.
Asignación de VM	Usuario-VM persistente, aprovisionamiento idempotente, arranque con bloqueo y estados visibles.
Tareas y eventos	Estados durables; historial, streaming y reconexión sin depender de la pestaña abierta.
Colas / agenda	Trabajo pendiente y programación fuera de las VMs; reintentos acotados e idempotencia.
Parada segura	No apagar durante trabajo activo o resultado financiero desconocido; persistir antes de parar.
Restauración / baja	Backups por usuario, restauración probada, retención, exportación y borrado según política.

Validación visual

Mostrar “creando”, “iniciando”, “trabajando”, “detenida”, “recuperando” y “error” con explicación y siguiente acción. Al cerrar y abrir la app se ve el progreso conservado, sin reiniciar una tarea ni borrar mensajes.

Pruebas

- API-01/02: sesión inválida bloqueada y acceso cruzado rechazado aunque se cambien IDs directamente en HTTP.
- VM-02/03: dos solicitudes concurrentes no crean ni despiertan dos VMs para el mismo usuario. La agenda despierta solo la correcta.
- VM-04/05: cerrar app, reiniciar worker/VM y cortar red; recuperar tareas sin duplicar efectos. No tratar una pestaña cerrada como cancelación.
- VM-06/07: restaurar datos del usuario correcto y revocar/borrar según política; verificar también la interfaz de estado.

Cierre: una tarea avanza con la app cerrada y aparece correctamente al volver. Aislamiento verificado desde el servidor y la infraestructura, además de la UI.

08 / F04: investigación, comparación y memoria

Semanas 5–6 | IA + integraciones + frontend + QA | P08–P09 y P16 inicial

Capacidad	Entrega concreta
Investigación útil	Respuesta con enlaces, fecha de consulta y límites; no inventar precio, stock o cobertura.
Comparación	2–3 opciones cuando existan; variante, vendedor, envío, total, disponibilidad y condiciones.
Navegación controlada	Dominios permitidos, sesión propia y solicitud al usuario para MFA/CAPTCHA.
Memoria personal	Ver/editar/borrar preferencias, procedencia, exportación y permiso de uso.
Límites de tarea	Tope de pasos, tokens, búsquedas, tiempo y reintentos; bloqueo comprensible al agotarse.
Seguimiento	Progreso ligado a eventos y ayuda/cancelación; no inferir éxito del texto del modelo.

Cómo se debe ver

Las tarjetas permiten comparar totales en MXN sin truncar variante o envío. Explicar cuando falta un dato; “sin disponibilidad confirmada” no equivale a disponible. Domicilios y datos personales se muestran solo en el alcance necesario.

Pruebas

- AI-01/02: dataset con precio/variante conocidos; fuentes correctas, total consistente y manejo de “sin resultados”.
- AI-03/04: instrucciones maliciosas en página o correo no amplían permisos ni extraen datos; límites cortan bucles.
- AI-05/06: editar/borrar memoria cambia respuestas futuras y no afecta B; logout/revocación corta conexiones nuevas.
- AI-07: errores de proveedor, timeout o respuesta inválida aparecen con recuperación, no con una comparación fabricada.
- VIS-04/07: precios largos, ofertas, una sola opción, falta de stock, imágenes rotas y nombres extensos en móvil.

Cierre: el usuario puede resolver investigación/comparación y controlar su memoria. Cobertura acotada y errores visibles; ninguna integración comercial se promete sin validación.

09 / F05: aprobación y compra simulada

Semana 7 | Backend de pagos + frontend + QA + seguridad | P10–P13 y P19 simulados

Construir primero el ciclo financiero con un simulador determinista que permita reproducir rechazos, tiempos fuera, duplicados y resultados desconocidos. El servidor, no el modelo, decide si una orden está autorizada.

Objeto	Regla
Cotización	Versión, producto/variante, vendedor, cantidad, total/moneda, envío, domicilio, vigencia.
Consentimiento	Usuario autenticado, cotización/versión, acción, máximo, expiración y evidencia; evitar reutilización.
Reserva	Atómica y acorde al saldo/límite; disponible y reservado separados si hay saldo administrado.
Pago / pedido	IDs y estados distintos. Una autorización de tarjeta no es compra confirmada.
Cancelación	Antes del compromiso externo, detener; después, solicitar cancelación/devolución y explicarlo.
Desconocido	Bloquear reintento de compra hasta consultar/conciliar; conservar trazabilidad.

Pantalla que revisaremos con más cuidado

Debe mostrar qué se comprará, a quién, cuánto como máximo, dirección parcial y hasta cuándo. “Aprobar”, “Cambiar” y “Rechazar” son acciones separadas. Pedir nueva aprobación si cambian condiciones fuera del alcance.

Pruebas

- PAY-01 a PAY-08 con simulador: sin aprobación, vencida, precio cambiado, replay, doble clic, saldo concurrente, evento duplicado/desordenado y timeout tras cobro.
- PAY-09/10: cancelación antes/después del compromiso y reembolso parcial. VIS-05/06/08: no ocultar cargos ni mostrar éxito antes del pedido confirmado.

Cierre: ninguna ruta de servidor ejecuta una compra sin consentimiento válido. Todos los estados, incluido “no sabemos aún”, pueden verse y probarse en la demo.

10 / F06: dinero y proveedores en sandbox

Semana 8, condicionada | Pagos + legal + QA | P01–P02, P12–P18 y P20

Flujo independiente	Prueba exigida
Cobrar el servicio: Stripe	Checkout/Billing test: alta, renovación, rechazo, cancelación y reembolso; estado de suscripción y CFDI cuando aplique.
Fondear cuenta: Finco	Identidad/titularidad y contrato; alta KYC, CLABE, abono SPEI firmado, límites y devolución en sandbox.
Pagar comercio	Emisor y comercio habilitados; autorización/captura, pedido, reversa y devolución parcial/total.
Conciliar	Libro auxiliar, proveedor y pedido reconciliados; diferencias y estados inciertos visibles.
Soporte	Permisos de intervención, historial, escalamiento y evidencia de cada ajuste.

Pruebas financieras completas

PAY-01 a PAY-12 con el sandbox oficial. Capturar IDs de proveedor, firma válida, deduplicación, idempotencia y consulta de estado. Simular fallos además del caso feliz. Verificar que ninguna llave o tarjeta real entre en chat, logs o memoria.

Revisión visual

- Cuenta distingue disponible, reservado y liquidado; no abona fondos por un mensaje de chat ni por un callback sin validar.
- Membresía y saldo de compras aparecen separados. No etiquetar una referencia CLABE como cuenta individual si el contrato no lo permite.
- Pago autorizado, pedido confirmado, devolución solicitada y reembolso recibido tienen textos diferentes.

Si Finco no está disponible

Mantener la integración financiera pendiente. Continuar investigación, comparación y carrito con pago directo por el usuario. Los mocks validan nuestro código, pero no sustituyen sandbox, contrato, elegibilidad ni conciliación real del proveedor.

No se enviarán fondos ni se harán compras reales como parte de estas pruebas de sandbox. Un piloto posterior con dinero exige el flujo habilitado y autorización operativa específica.

11 / F07: validación integral antes de piloto

Semanas 9–10 | QA + seguridad + infraestructura + operación | P19–P22

Frente	Prueba de salida
Recorrido completo	Alta → tarea → comparación → aprobación → ejecución/pedido → seguimiento → devolución. Ver errores y reanudación.
Seguridad	Autorización cruzada, injection, secretos, recuperación de cuenta, acceso de soporte y revocación.
Resiliencia	Caída de API/worker/VM y proveedor durante ejecución; restauración de backup y conciliación antes de reabrir pagos.
Accesibilidad / visual	Matriz móvil/escritorio, teclado, zoom, lector de pantalla; capturas aprobadas para estados críticos.
Rendimiento / costo	TTFT, primera herramienta, tarea completa, arranque y carga. Límites por usuario, cuota y alertas.
Operación	Manual de incidencias, conciliación diaria, ayuda, kill switch, rollback y guardias acordadas.

Evidencia que se revisa en la demo

- Versión exacta, entorno y datos de prueba; reporte de casos ejecutados, fallidos, omitidos y bloqueados.
- Capturas en móvil/escritorio del mismo build; videos del flujo y recuperación; logs redactados y conciliación de operaciones de prueba.
- Ensayo de rollback: volver a versión estable sin borrar ledger ni duplicar órdenes; migrations compatibles o plan de recuperación probado.

Puerta de salida

Cero defectos críticos/altos abiertos de aislamiento, dinero o pérdida de datos. Todas las pruebas críticas ejecutadas y aprobadas; ninguna se marca aprobada por estar omitida. Una falla estética se clasifica por su impacto, no se minimiza si oculta monto o acción.

Si existe un bloqueo externo de dinero, puede aprobarse solo un piloto sin ese flujo. El alcance permitido debe quedar escrito; no declarar la plataforma financiera lista.

12 / F08: piloto por invitación

Semanas 11–12 | Producto + operación + QA + pagos | P23

Invitar 25–50 personas del perfil, con cobertura y límites comunicados. Comenzar por un grupo menor y ampliar si no aparecen fallos críticos. Compras reales solo bajo programa/flujo autorizado; mientras tanto, mantener investigación o pago directo del usuario.

Qué observamos	Cómo lo validamos
Primer uso	Registro y primera tarea útil; dónde se pierde, qué texto no entiende y dónde requiere ayuda.
Confianza visual	Usuario identifica monto, vendedor, estado, siguiente paso y diferencia entre simulado/real.
Calidad	100 tareas del alcance como muestra inicial: éxito, intervención, falla y causa; separar ayuda del usuario (3DS) de operador.
Dinero	100% de compras reales con consentimiento válido y trazabilidad; conciliación diaria sin diferencias inexplicadas al cierre.
Operación	Tiempo de respuesta/resolución, solicitudes de ayuda, cancelaciones, devolución y carga por operador.
Economía	Tokens, búsquedas, VM, red, soporte y costos externos por tarea y usuario.

Metas iniciales, no resultados

- ≥90% de tareas del alcance completadas sin operador interno en la muestra de 100; revisar causas y sesgo de la muestra. No implica compras universales ni garantía estadística.
- Cero gasto no autorizado y cero acceso cruzado. Si ocurre, detener nuevas compras, investigar y decidir reanudación; no esconderlo en un promedio.
- Al menos una sesión observada de usabilidad por recorrido crítico, con 5–8 participantes del perfil para detectar problemas; no tratar esa muestra como representación del mercado.

Cierre

Se avanza con evidencia de utilidad, seguridad y soporte, no por cumplir una fecha. Las limitaciones se incorporan al producto y al siguiente sprint. Sin conciliación y postventa, no se amplían pagos.

13 / F09: estabilización y escala controlada

Semanas 13–16 | Equipo de producto + ingeniería + operación | P22, P31 y P33

Trabajo	Validación
Corregir por impacto	Primero errores de dinero/aislamiento/datos; después tareas fallidas, abandono, latencia y detalles visuales.
100–300 personas	Cohortes graduales solo con capacidad y soporte. No asumir que central de un nodo tiene HA.
Capacidad 25/100/1,000	Carga representativa en staging: API/colas con ejecutores simulados + muestra de VMs reales. No crear 1,000 VMs por defecto.
Costos reales	Actualizar escenarios del PDF v1.2 con consumo y cotizaciones; distinguir gastos únicos de operación.
VM y modelo	Comparar 4/8 GB, horas activas, arranque y consumo. DO apagado no ahorra mientras exista.
Continuidad	Cambiar proveedor/modelo sin mezclar datos, duplicar efectos ni romper el contrato de herramientas.

Pruebas que se repiten

- Regresión de recorridos críticos, visual móvil/escritorio y permisos por cada release.
- Carga y recuperación con picos; comprobar límites de proveedor, cola, tasa de error y cola envejecida. Un ejecutor simulado no valida RAM ni navegador real.
- Snapshot/restauración por usuario y fallo de dependencia. Reconciliar antes de reactivar ejecución financiera.
- Usabilidad con usuarios recurrentes y nuevos; no optimizar solo para quienes ya aprendieron la interfaz.

Cierre

Antes de adquirir más usuarios: calidad, latencia, costo y postventa medidos por cohorte, límites probados y responsables de operación asignados. El precio final incorpora Finco y otros costos pendientes.

14 / F10: canales, conexiones y apps

Semanas 17–20, condicionadas | Integraciones + móvil + seguridad + QA | P24–P28

Canal / conexión	Construcción y pruebas
WhatsApp elegible	Confirmación del caso con reglas vigentes; consentimiento, opt-out, ventana y plantillas; duplicados y entrega. No usar un puente no oficial para el negocio.
Identidad multicanal	Asociación autenticada de cuenta; no usar teléfono o texto como autorización suficiente; eventos convergen a la misma tarea.
Correo / calendario	Scopes mínimos, verificación/evaluación cuando aplique, expiración y revocación. Correos y eventos maliciosos no amplían permisos.
Voz	Transcripción y confirmación del monto/destinatario; no ejecutar pagos por una transcripción ambigua. Límites de audio y costos.
Apps iOS/Android	Adaptar navegación, accesibilidad, notificaciones y deep links; revisar cobro digital por storefront antes de diseñar checkout.

Cómo validaremos la apariencia

- Mismo pedido, importe y estado en web, móvil y notificación. Textos largos y enlaces abren la tarea correcta; no revelan datos sensibles en pantalla bloqueada.
- Enlace de notificación no ejecuta automáticamente una compra ni reutiliza consentimiento vencido.
- iOS/Safari y Android reales para teclado, cámara/adjuntos, safe areas, push y reanudación. Emulación de viewport no sustituye pruebas de plataforma.

Puerta de salida por canal

Cada canal es una entrega independiente. Si WhatsApp no admite el asistente generalista en México, no se lanza ese uso; la PWA continúa. No presentar una implementación técnica como autorización comercial.

Las apps y conexiones externas pueden necesitar tiempos de revisión fuera del calendario. Mantener la misma fuente de verdad, sin duplicar permisos en cada canal.

15 / F11: cobertura, recurrencias y continuidad

Semanas 21–24 y evolución posterior | Producto + pagos + operación + ingeniería | P29–P33

Ampliación	Condición para publicar
Nuevo comercio/categoría	API/convenio o flujo permitido; variante/stock/total, confirmación, cancelación, entrega y devolución probados.
Pago de servicios	Agregador y contrato, referencia correcta, idempotencia, recibo y reversa; no extrapolar compras de bienes.
Recurrencia	Mandato con monto máximo, frecuencia, comercio, vigencia y revocación. Avisos y nueva aprobación al salir del alcance.
Afiliación / vendedores	Contrato, divulgación y facturación; no sesgo oculto ni ingreso financiero supuesto.
Escala mayor	Capacidad, cuotas, HA efectiva, recuperación y soporte antes de habilitar cohortes nuevas.
Cambio de motor/proveedor	Exportación, formato de memoria, permisos, sesiones y reconciliación. Pruebas de compatibilidad y rollback.

Pruebas nuevas antes de repetir compras

- Dos disparos de agenda generan una sola intención; no pagar dos veces por reintento ni por cambio de canal.
- Mandato revocado/vencido bloquea nuevas ejecuciones. Cambios de precio, domicilio o vendedor fuera de lo aprobado exigen nuevo permiso.
- Horario y zona del usuario explícitos; cambios de horario o ejecución atrasada no adelantan ni duplican cargos.
- Caída en pleno pago mantiene estado desconocido hasta reconsulta; no libera reserva ni ejecuta el siguiente intento a ciegas.

Después de la semana 24

Evolución por métricas: parches, evaluación de modelos, restauración, seguridad, usabilidad, conciliación y economía por cohorte. La automatización se amplía solo con evidencia de que conserva control, recuperación y soporte.

La semana 24 no es “todo terminado”. Es el cierre de una expansión acotada; cada nueva capacidad repite las puertas de diseño, pruebas, piloto y operación.

16 / Pantallas que vamos a revisar

Inventario de UX; cada pantalla tiene estado normal, vacío, carga y error cuando corresponda.

Pantalla	Qué debe verse claro	Casos que no podemos omitir
Alta / recuperación	Mayoría de edad, términos, privacidad, verificación y siguiente paso.	Código vencido, intentos, error de red y cuenta ya existente.
Inicio / chat	Qué puede hacer, fuentes y tarea en curso.	Conversación vacía, adjunto inválido, respuesta parcial y error de modelo.
Lista / detalle de tarea	Estado, objetivo, pasos, bloqueo y cancelar.	VM iniciando, detenida, recuperación, sin conexión y tarea atrasada.
Comparación	Variante, vendedor, envío, total, stock y vigencia.	Sin resultados, una opción, imagen rota, nombre/precio largos y datos faltantes.
Aprobación	Producto, total máximo, vendedor, dirección parcial y caducidad.	Cotización cambiada, vencida, rechazo, doble clic y reautenticación.
Cuenta / tarjeta	Proveedor/titularidad, disponible, reservado, movimientos y bloqueo.	KYC pendiente/rechazado, saldo sin confirmar, tarjeta bloqueada y abono pendiente.
Pedido / devolución	Pago y pedido separados, seguimiento, ayuda y devolución.	Cobro sin pedido, resultado incierto, parcial, disputa y retraso.
Memoria / conexiones	Qué guarda, origen, editar/borrar y permisos por integración.	Sin datos, acceso expirado, revocación y eliminación pendiente.
Plan / facturas / soporte	Precio, recurrencia, cancelación, historial y contacto.	Cobro rechazado, suscripción cancelada, factura fallida y soporte abierto.
Panel de operación	Permisos, cola de excepciones y evidencia de intervención.	Acceso denegado, ajuste con doble control y diferencia de conciliación.

El panel de operación es una interfaz separada por roles, no una pantalla accesible al consumidor. Ocultar un menú no basta: el servidor valida cada permiso. Los datos sensibles en las capturas deben ser sintéticos o estar redactados.

17 / Criterios visuales verificables

Lista VIS: no se limita a que “se vea bonito”; exige que el usuario entienda y pueda actuar.

ID	Qué revisamos	Aceptación
VIS-01	Reflow y tamaños	Sin scroll horizontal a 320 CSS px en flujos normales; tarjetas/tablas se adaptan, acciones alcanzables.
VIS-02	Texto y contraste	Texto legible: contraste normal ≥4.5:1, texto grande ≥3:1; estados y controles con contraste/indicadores suficientes.
VIS-03	Teclado y foco	Orden lógico; foco visible y no oculto, sin trampas. Dialogo gestiona entrada/salida y devuelve foco.
VIS-04	Contenido extremo	Nombres, variantes, URLs, precios y domicilios largos no tapan montos ni acciones.
VIS-05	Montos y condiciones	MXN explícito, separadores consistentes, total/envío/comisión claros; sin redondeos que alteren el permiso.
VIS-06	Estados verdaderos	No marcar éxito por clic o texto del modelo. Incierto, pagado, pedido y reembolso son distinguibles.
VIS-07	Recursos y carga	Fuentes e imágenes sin saltos perjudiciales; placeholders y fallback; no depender de una imagen para información crítica.
VIS-08	Teclado móvil / overlays	Campos y confirmación no quedan tapados por teclado, barra fija, modal o safe area.
VIS-09	Táctil y acciones	Objetivos ≥24×24 CSS px o separación/excepción válida; apuntar a 44×44 para acciones principales.
VIS-10	Feedback / desconexión	Carga, timeout, offline y reconexión explicados; no spinner infinito ni repetición ciega de pago.
VIS-11	Validación y errores	Campo y explicación vinculados, instrucciones accionables; toast no es el único registro de un error importante.
VIS-12	Regresión visual	Capturas deterministas por estado/viewport; comparar con referencia revisada y aceptar cambios deliberadamente.

Referencia de accesibilidad: WCAG 2.2 AA. Los umbrales anteriores son criterios del proyecto, no una certificación. Lector de pantalla, semántica, teclado, zoom y accesibilidad de procesos requieren revisión adicional. https://www.w3.org/TR/WCAG22/

18 / Dispositivos y navegadores de prueba

Matriz mínima propuesta; expandir con los dispositivos reales del piloto.

Entorno	Prueba	Cuándo
320 CSS px y zoom	Reflow, texto aumentado hasta 200%, navegación y aprobación sin recortes.	Cada cambio de layout; todas las pantallas críticas antes de piloto.
Android 360×800 / 390×844	Chrome: conversación, teclado, comparación, aprobación, archivos y reconexión.	Capturas automatizadas por PR crítico y revisión real por release.
Móvil grande 430×932	Contenido largo y densidad, teclado y barras fijas.	Antes de aprobar componentes y regresiones.
iPhone / Safari real	Teclado, scroll/modal, safe area, sesión, PWA y notificaciones cuando apliquen.	F01 visual y cada release; capacidades de plataforma desde su fase.
Tablet 768×1024 / 1024×768	Orientación, navegación, tablas y diálogos.	Cambios responsive y previo a piloto.
Escritorio 1440×900	Chrome y Firefox: columnas, streaming, foco y todas las acciones.	Recorridos automáticos y revisión de cada release.
Safari escritorio / accesibilidad	Safari real y VoiceOver; NVDA/Chrome o Firefox cuando estén disponibles.	Previo a piloto y cambios de navegación/semántica.

Qué demuestra cada tipo de prueba

Emular un viewport sirve para layout, no demuestra que funcione Safari/iOS, teclado del sistema, push, cámara o instalación PWA. Playwright WebKit ayuda a detectar diferencias pero no reemplaza Safari real. Si el entorno cloud no dispone de un dispositivo, registrar esa prueba como pendiente y usar dispositivo físico o servicio de pruebas autorizado al ejecutarla.

Contenido de las capturas

- Misma versión, fixtures, idioma y estado. Fijar fechas/animaciones y enmascarar solo datos dinámicos necesarios; no ocultar precio ni estado financiero.
- Guardar referencia y comparación. Diferencias en total, botón de aprobación o información cortada bloquean; cambios de diseño intencionales se revisan antes de renovar la referencia.
- No usar una tolerancia global de píxeles para aprobar cambios sin inspección. Una diferencia pequeña puede afectar un dígito del monto.

19 / Estados y pruebas con personas

Validar apariencia, comprensión y recuperación: tres cosas distintas.

Estado	Mensaje / comportamiento esperado
Vacío	Qué puede hacer y ejemplo de siguiente acción, sin actividad ficticia.
Cargando / iniciando VM	Qué se está preparando; progreso honesto y recuperación si tarda.
Trabajando con app cerrada	Tarea persistida; al volver muestra eventos reales, no reinicia.
Esperando al usuario	Permiso o decisión requerida con contexto y vencimiento.
Sin conexión	Distinguir conexión del cliente de estado del servidor; no asumir tarea cancelada.
Sin stock / precio cambió	Opción no disponible o nueva cotización; no reciclar aprobación anterior.
Pago desconocido	“Estamos verificando el resultado”; no habilitar otra compra equivalente a ciegas.
Pedido confirmado	ID y datos del comercio; autorización de tarjeta por sí sola no basta.
Reembolso solicitado / recibido	Etapas separadas y vinculadas al pago original.
Cancelación	Explicar si detuvo ejecución o si está solicitando reversa/devolución externa.

Sesión de usabilidad propuesta: 5–8 personas del perfil

- **UX-01:** pedir una tarea y encontrar su avance sin ayuda; registrar bloqueos y dudas, no solo clics.
- **UX-02:** comparar y explicar en sus palabras precio final, vendedor y variante antes de aprobar.
- **UX-03:** rechazar/cambiar y distinguir “pago pendiente”, “pedido confirmado” y “reembolso recibido”.
- **UX-04:** cancelar una tarea, revocar conexión y encontrar soporte; comprobar que no teme perder control.

Meta inicial: al menos 4 de 5 participantes completan los recorridos centrales sin guía del moderador; todos comprenden total y alcance antes de autorizar. Un malentendido financiero bloquea aunque el promedio sea alto. Es una prueba cualitativa de detección, no una estimación estadística de adopción.

20 / Pruebas de API, identidad y seguridad

Casos críticos ejecutados contra servidor y herramientas; no basta que la UI oculte botones.

ID	Caso	Resultado exigido
API-01	Sesión ausente, vencida o revocada	No accede ni ejecuta. La UI pide recuperar sesión sin perder la tarea persistida.
API-02	Cambiar tenant_id/task_id/order_id en HTTP	Servidor rechaza acceso a otro usuario; no filtra contenido, existencia sensible ni credenciales.
API-03	Campos manipulados / importes inválidos	Valida esquema, moneda, centavos, versión y límites; el modelo no elige identidad efectiva.
API-04	Reintento / doble solicitud	Una intención lógica, efecto único; respuesta recuperable e identificadores consistentes.
API-05	Error / timeout / rate limit	Contrato de error entendible, reintentos seguros acotados y estado durable.
API-06	Roles de soporte y ajustes	Solo operaciones permitidas; intervención auditada y doble control cuando corresponda.
SEC-01	A intenta usar secretos/sesión de B	Bloqueado en API, VM, navegador, almacenamiento y backups; no solo en chat.
SEC-02	Injection en web/correo/adjunto	Contenido no confiable no cambia permisos, comercio, destinatario ni herramientas efectivas.
SEC-03	Enlace a metadata cloud / red interna	Egreso/SSRF bloqueados desde todos los caminos de herramienta que puedan acceder.
SEC-04	Secretos en prompt/log/captura	No se exponen llaves globales, PAN/CVV ni datos de otros usuarios; redacción probada.
SEC-05	Recuperación de cuenta / alta de conexión	Reautenticación y evidencia según riesgo; atacante no toma sesión con un texto o teléfono.
SEC-06	Revocación / cierre / soporte temporal	Detiene nuevas acciones; expira privilegios y ejecuta política de retención/borrado.

Pruebas con datos sintéticos y entornos propios/autorizados. Revisar amenazas al principio y repetir tras cambios de herramientas, permisos, navegador, almacenamiento o proveedor de identidad.

21 / Pruebas de la VM y recuperación

La VM exclusiva es un requisito del producto, no una optimización intercambiable por perfiles compartidos.

ID	Prueba	Resultado exigido
VM-01	Dos usuarios con navegadores y archivos	Cada uno conserva memoria, disco, cookies y credenciales propios. No heredar logins de la imagen.
VM-02	Alta/despertar concurrentes y reintentos	Una VM asignada por usuario; idempotencia y bloqueo impiden duplicados y asociaciones cruzadas.
VM-03	Detenida y evento/horario central	La agenda/cola externa despierta la correcta; tarea no depende de cron en la VM apagada.
VM-04	Cerrar app / cambiar de dispositivo	Trabajo continúa si estaba activo; se reanuda visualización sin volver a ejecutar.
VM-05	Reinicio durante una herramienta o pago	Estado durable; consultar resultado externo antes de repetir. No apagar un pago sin resolver.
VM-06	Restaurar backup de A	Datos y permisos de A, sin restaurar secretos globales o datos de B. Medir pérdida y tiempo de recuperación.
VM-07	Baja, revocación y recuperación	Respetar retención legal; revocar sesiones, borrar según política y demostrar que no quedan copias accesibles indebidas.

Red, imágenes y actualizaciones

Imagen base versionada sin datos personales; parches probados en VMs de ensayo antes de la flota. Acceso privado, identidad breve, límite de salida y sin acceso lateral entre usuarios. Una copia no es un plan de recuperación hasta restaurarla.

Datos de aceptación por registrar

- Tiempo de creación y despertar p50/p95, CPU/RAM de Hermes+navegador, disco, red, fallos y costo por usuario.
- RPO/RTO reales de una restauración: pérdida máxima de datos y tiempo de recuperar servicio; fijar objetivos tras medir, sin prometerlos por precio de proveedor.
- Backups de disco personal y ledger central tienen objetivos diferentes. Restaurar el agente no permite retroceder asientos ni repetir compras ya comprometidas.

22 / Pruebas de calidad del agente y modelos

AI: corpus versionado de tareas, herramientas y resultados. Sin evaluar capacidad solo por tono de la respuesta.

ID	Caso	Resultado exigido
AI-01	Investigación con evidencia conocida	Fuentes identificables y vigentes para el caso; distingue dato faltante de hecho.
AI-02	Producto, variante, stock y total	No sustituye variante o vendedor sin permiso; separa envío, comisión e impuestos del comercio.
AI-03	Instrucción maliciosa en contenido	No sigue instrucciones de la página/correo que amplíen permisos o desvíen fondos/datos.
AI-04	Bucle, herramienta lenta o cuota agotada	Topes de pasos/tokens/búsquedas/tiempo detienen; comunica bloqueo y conserva estado.
AI-05	Memoria editar/borrar/exportar	Respeta cambio y procedencia; no mezcla preferencias o datos entre personas.
AI-06	Conexión revocada o permiso insuficiente	No usa acceso previo; solicita reconexión/alcance mínimo sin pedir secreto por chat.
AI-07	Respuesta inválida del modelo o tool	No ejecuta JSON malformado, campos fuera de contrato o una herramienta no aprobada; recuperación segura.

Lote de evaluación inicial

100 tareas del alcance, con casos de comparación, lectura visual, memoria, seguimiento y fallos. Usar los mismos casos/criterios al comparar modelos; registrar versión, prompt, herramientas, parámetros y región. Reservar casos para regresión sin ajustar todo el diseño a las mismas preguntas.

Qué medimos

- Correctitud de la tarea y herramientas, error de variante/importe, necesidad de operador, rechazos correctos y fallos peligrosos.
- Tiempo al primer token, primera herramienta válida, total, tokens facturados y costo. Separar latencia de modelo, navegador, cola y VM.
- Resultados por categoría y riesgo, no solo promedio. Un único pago no autorizado o fuga de datos bloquea la ruta afectada.

No mezclar la muestra de 100 tareas de viabilidad con resultados futuros del piloto como si fueran observaciones independientes. Reportar cada ejecución y su alcance. Ningún benchmark fue ejecutado al crear este plan.

23 / Pruebas de dinero, pedidos y postventa

PAY: primero simulador, después sandbox oficial. Los proveedores pendientes mantienen casos bloqueados.

ID	Escenario	Resultado exigido
PAY-01	Sin consentimiento / vencido / otro usuario	Servidor bloquea ejecución; no basta un “sí” en texto.
PAY-02	Cambia cotización o condición autorizada	Nueva versión/aprobación al salir del alcance; no aceptar consentimiento anterior.
PAY-03	Replay, doble clic o reintento	Misma intención lógica; no segundo pago/pedido ni doble reserva.
PAY-04	Dos compras y saldo limitado	Reserva atómica y límites; no sobregiro por concurrencia.
PAY-05	Webhook sin firma / replay / duplicado	Validación, deduplicación y auditoría; sin abono o transición indebida.
PAY-06	Eventos llegan fuera de orden	Consultar fuente y conciliar; no retroceder un estado confirmado incorrectamente.
PAY-07	Timeout después de posible cobro	Marcar desconocido y consultar; no liberar/recomprar a ciegas.
PAY-08	Tarjeta autorizada sin pedido aceptado	Separar estados y resolver reversa/soporte; UI no dice “comprado”.
PAY-09	Cancelar antes/después de compromiso	Detener si aún es posible; después solicitud externa trazable, sin falsa cancelación.
PAY-10	Reembolso parcial / tarjeta cerrada	Vincular pago original, ruta con emisor y conciliación; distinguir solicitado de recibido.
PAY-11	3DS, rechazo, captura/reversa y SPEI	Intervención legítima, límites y saldo según proveedor; no evadir autenticación.
PAY-12	Cobro de membresía y operación contable	Servicio separado de fondos/GMV; renovación, baja, cobro fallido, CFDI y ajustes auditados.

Cada caso debe guardar IDs de consentimiento/cotización/pago/pedido/proveedor y asientos afectados, sin PAN/CVV ni secretos. Prueba de éxito y al menos una falla por integración; mock aprobado no cuenta como integración externa aprobada.

24 / Rendimiento, carga y presupuesto

PERF: objetivos iniciales por validar, no SLA ni resultados medidos.

ID	Qué se prueba	Criterio / evidencia
PERF-01	Interfaz y tareas interactivas	En pantallas representativas: meta LCP≤2.5s, INP≤200ms, CLS≤.1. Laboratorio detecta regresiones; p75 real requiere datos suficientes del piloto.
PERF-02	Modelo y herramientas	Meta inicial p95 TTFT≤1.5s y primera herramienta≤3s para tareas cortas con VM lista; registrar casos, red y errores. No aplicar a todo tipo de tarea.
PERF-03	VM fría y cola	Medir creación/despertar, espera y recuperación por separado. UI informa estado; acordar máximo y política tras medir, sin spinner indefinido.
PERF-04	Escala y costos	Usuarios 25/100/1,000 como escenarios; concurrencia modelo1/5/20 y picos API/colas. Registrar cuota, backlog, tasa de error, latencias y gasto.

Condiciones de la prueba

- Fijar build, dataset, región, tamaño de VM, caché, modelo y límites. Separar arranque frío/caliente y comparar la misma carga.
- Entradas/salidas y pasos cuentan completos: TPS de generación, TPM de cuota y tiempo total son medidas diferentes.
- Cargar APIs/colas con simulación es útil, pero no demuestra que 1,000 navegadores/VMs reales tengan igual rendimiento. Validar una muestra real antes de extrapolar.
- Límites y alertas por usuario/tarea/proveedor; probar que el límite funciona. Las pruebas usan presupuesto acotado y no aprovisionan flotas o consumen API pagada ilimitadamente.

Qué pasa si no se cumple

Atribuir demora a modelo, VM, navegación, cola o proveedor; corregir la causa y repetir el caso afectado. Si se ajusta una meta, documentar por qué cambia y su impacto; no cambiar silenciosamente el umbral para marcar verde.

Métricas Web Vitals son metas de experiencia, no sustituyen pruebas de accesibilidad o seguridad. Referencia: https://web.dev/articles/vitals. TTFT/primera herramienta se miden en nuestra integración, no se deducen de precios o publicidad.

25 / Pruebas automáticas y proceso de release

Automatizar lo repetible y revisar con personas lo que exige comprensión, accesibilidad o juicio visual.

Momento	Verificación	Qué bloquea
Al cambiar reglas	Pruebas de estados, permisos, importes, reservas, cotización e idempotencia; integraciones de DB/cola cuando aplique.	Invariantes financieras, aislamiento o estados incorrectos.
Cada cambio de UI crítico	Tipos/build, recorrido E2E determinista y capturas de componentes/pantallas afectadas; accesibilidad automática.	Recorrido roto, montos ocultos, acción inaccesible o cambio visual no revisado.
Al integrar a rama estable	API/VM/AI/PAY afectados y smoke del conjunto; las pruebas sandbox solo donde el acceso exista.	Falla crítica o dependencia requerida omitida/bloqueada.
Antes de publicar	Staging del build exacto, regresión crítica, dispositivos reales, revisión manual, migración y rollback.	Defecto de alto impacto, evidencia insuficiente o responsable de incidente sin asignar.
Después de publicar	Smoke sin efectos financieros indebidos, métricas y errores; comprobar colas y conciliación.	Degradación exige detener ruta/rollback seguro según el caso.

Reporte de ejecución

Por caso: ID, fase, versión, entorno, dato/fixture, pasos, resultado esperado, resultado observado, evidencia y responsable. Estado: **pendiente, aprobado, fallido, bloqueado u omitido justificado**. Incluir conteos; cero pruebas ejecutadas no significa aprobado.

Evidencia útil

- Captura/video para apariencia y flujo; eventos de servidor y proveedor para compras; no usar screenshots como única prueba de saldo o autorización.
- Diferencias visuales aprobadas manualmente y rastreadas al cambio. No aceptar automáticamente todas las capturas para pasar CI.
- Credenciales separadas, logs redactados y fixtures sintéticos. Conservar evidencia por política, sin acumular datos personales innecesarios.

26 / La demo con la que cerraremos cada etapa

Revisión breve del incremento real, con los mismos criterios definidos antes de implementarlo.

Paso	Qué enseñaremos
1. Alcance de la entrega	Qué historias/casos incluye y qué queda bloqueado o fuera.
2. Flujo normal	Usuario nuevo completa la acción desde la pantalla de entrada hasta resultado verificable.
3. Móvil y escritorio	Mismo flujo con contenido largo, teclado, zoom y acciones visibles.
4. Error y recuperación	Timeout/desconexión/fallo; siguiente paso claro y estado conservado.
5. Cancelación / control	Rechazar, cambiar, cancelar y revocar según la fase; confirmar alcance en servidor.
6. Segundo plano	Cerrar app, reabrir y observar continuidad; parar/despertar la VM cuando aplique.
7. Dinero / incertidumbre	Mostrar escenarios pendientes; no forzar éxito para que la demo se vea completa.
8. Evidencia	Casos ejecutados y fallidos, capturas, eventos y costos relevantes de la misma versión.
9. Decisión	Avanzar, corregir o avanzar solo un alcance menor explícito; dueño y siguiente acción de cada bloqueo.

Una tarea está terminada cuando…

- Cumple aceptación funcional y visual; maneja carga, vacío, error y recuperación aplicables.
- Tiene evidencia reproducible, revisiones y pruebas relevantes aprobadas. No muestra datos simulados como reales ni deja secretos en cliente/logs.
- Respeta permisos, observabilidad, cancelación y soporte; migración/rollback documentados si afecta datos o procesos.
- La documentación de arranque/operación refleja lo que existe. Los límites y dependencias quedan visibles.

Responsables propuestos

Producto/UX evalúan comprensión y alcance; frontend consistencia visual/accesibilidad; backend/pagos invariantes; IA/infra aislamiento y recuperación; QA evidencia/regresión; operación conciliación/postventa. Una persona puede tener varios roles, pero los ajustes financieros sensibles requieren revisión independiente.

27 / Dependencias y cobertura del backlog

P00–P33 provienen del plan v1.2; esta tabla los aterriza sin eliminar capacidades ni saltar permisos.

Fase	Backlog principal	Dependencia para cerrar
F00	P00, P01, P20 diseño	Usuario/caso y flujo de fondos definidos; riesgos explícitos.
F01	P05–P06 iniciales; P10–P11/P19 mock	Diseño y fixtures aprobados; simulación identificada.
F02	P03–P04, P07/P21 viabilidad	Herramientas/accesos y dos VMs; aislamiento y motor probados.
F03	P05–P07, P17 y P21	Decisión técnica F02; identidad/agenda/estado durables.
F04	P08–P09 y P16 inicial	Permisos/VM propios; fuente/comercio de investigación habilitado.
F05	P10–P13/P19 simulados	Contratos de orden/cotización/consentimiento fijados.
F06	P01–P02, P12–P18 y P20	Identidad/contrato Finco, emisor/comercio, Stripe y sandbox según flujo.
F07	P19–P22 completos para alcance	Integraciones requeridas, seguridad y evidencia integral.
F08	P23	Puertas de piloto y responsables; pagos solo si flujo autorizado.
F09	P22, P31 y P33	Datos del piloto y capacidad/soporte disponibles.
F10	P24–P28	WhatsApp elegible, OAuth/tiendas y permisos específicos.
F11	P29–P33	Contratos de nuevas capacidades, postventa y economía medidas.

Trabajos que avanzan en paralelo

Legal/proveedores desde semana 1; diseño y viabilidad en quincena inicial; soporte/conciliación desde antes del piloto. Son frentes de equipo, no una promesa de plazos del proveedor. Si no hay acceso, terminar mocks y contratos internos, mantener el gate externo abierto.

Límites de calendario y presupuesto

El presupuesto v1.2 de desarrollo cubre cuatro meses; fases de semanas 17–24 requieren caja y dedicación posteriores. Mantener PWA como canal base y no ocultar este costo. Una VM por usuario se conserva durante todas las etapas; ahorro por parar depende del proveedor.

28 / Primer sprint listo para descomponer

Semana 1: UX navegable y cimientos. La semana 2 conecta la prueba técnica; no todo el backend de producción.

Ticket	Entrega	Aceptación mínima
DEV-001	Alcance y recorrido	Tres tareas elegidas, una compra simulada completa y límites escritos.
DEV-002	Componentes / tokens de diseño	Botones, tipografía, color, formularios y estados accesibles en móvil/escritorio.
DEV-003	Base reproducible	Proyecto inicia con documentación, lockfile, variables sin secretos y checks mínimos.
DEV-004	Inicio/chat y lista de tareas	Crear tarea simulada, abrir detalle y volver sin perder estado del fixture.
DEV-005	Comparación	Variante, vendedor, envío, total y fuente; sin stock/precio largo probados.
DEV-006	Aprobación/rechazo	Condiciones exactas, vigencia, cambiar/rechazar; no confundir con pago real.
DEV-007	Resultado y pedido simulado	Éxito, fallo y desconocido separados; historial y ayuda visibles.
DEV-008	Estados y reconexión simulada	Carga, vacío, offline y error con recuperación; no spinner permanente.
DEV-009	Pruebas visuales y accesibilidad	VIS aplicables, capturas en 360/390/1440, teclado/zoom y revisión manual.
DEV-010	Demo y siguiente sprint	Recorrido completo, defectos priorizados, decisiones registradas y plan de dos VMs para F02.

Lo primero que vamos a trabajar: DEV-001 y DEV-002, seguidos por la demo web DEV-003 a DEV-008. La primera entrega que verás será el flujo navegable completo; después lo conectaremos a Hermes y a la plataforma segura, etapa por etapa.

Referencia del proyecto: Roadmap_agente_Mexico_Hermes_v1_2.pdf (48 páginas), con requisitos, presupuesto y 73 fuentes. Este nuevo documento es una propuesta de orden de desarrollo y aceptación, no un registro de pruebas ya pasadas. No cambia contratos, tarifas ni elegibilidad de proveedores.